

Development and Application of an AI-Powered Adaptive Course Recommender System in Higher Education: An Example from K University

Jinsook Lee[†] (Korea University Data Scientist)

Kibum Moon (Korea University Data Scientist)

Suyeon Han (Korea University Data Engineer)

Sukang Lee (Korea University Data Engineer)

Hyejung Kwon (Korea University Administrator)

Jaeho Han (Korea University Head Administrator)

Gyutae Kim (Korea University Professor)

This paper outlines the development process of an AI-based elective course recommendation system on the basis of rapid prototype methodology (RP), from algorithm modeling to development of a user interface and follow-up survey. The algorithms used to produce recommendations employed either user-based collaborative filtering or a class history-based statistical model, incorporating students' course ratings and course enrollment history data. The system was implemented on the campus portal website in July 2020, and a satisfaction survey was conducted. Our results, based on 782 responses, demonstrated that the statistical-based model had significantly higher satisfaction than the collaborative filtering model. However, a follow-up survey based on course wish list and course registration data found that Recall@21 for the collaborative filtering model was about 37% and 43%, respectively, compared with 18% and 14%, respectively, for the statistical-based model. Thus, we found a difference between satisfaction with the recommended list and actual course behavior. In their responses, students regarded their academic interests as the top priority when choosing elective courses, and noted that keywords, capable of fully describing the lectures, were vital information due to ambiguous course titles. This study is expected to contribute to the further development and real application of AI-based recommendation systems in Korean higher education institutions.

Keywords : Artificial intelligence, Recommender system, Adaptive learning, Higher education, Rapid prototyping

[†] Correspondence : Jinsook Lee, Korea University, gupye@korea.ac.kr

대학의 AI 기반 맞춤형 강의 추천 시스템 개발 및 실제 적용 사례 연구: K 대학을 중심으로

이 진 숙[†] (고려대학교 데이터 사이언티스트)
문 기 범 (고려대학교 데이터 사이언티스트)
한 수 연 (고려대학교 데이터 엔지니어)
이 수 강 (고려대학교 데이터 엔지니어)
권 혜 정 (고려대학교 과장)
한 재 호 (고려대학교 팀장)
김 규 태 (고려대학교 교수)

〈요 약〉

본 연구는 대학혁신을 위한 인공지능 기반의 적응형 학습인 AI 기반 교양 강의 추천 시스템을 래피드 프로토타입 모형에 기반하여 개발하고, 실제 교내 포털 시스템에 적용하여 이용 결과를 분석하는 것에 목적을 두었다. 해당 서비스는 2020년 7월 교내 포털 시스템에 적용하였다. 추천 기능에 이용된 알고리즘은 사용자 기반 협업 필터링과 수강 이력 기반 통계 알고리즘을 이용하였으며, 각 모델당 21개의 교양 강의를 추천하였다. 서비스 만족도 설문조사를 진행한 결과, 782명의 응답을 수집하였고 협업 필터링 알고리즘보다 통계 기반 알고리즘의 만족도가 유의미하게 높은 것을 확인하였다. 그러나 실제 사후 추적 조사 결과, 2020년 2학기 희망 강의로 등록된 강의 내역과 실제 수강 내역에서 추천된 강의를 분석했을 때 협업 필터링 알고리즘의 Recall@21이 각각 약 37%와 43%로 통계 기반 알고리즘의 결과인 18%와 14%에 비해 높은 것으로 나타났다. 또한, 학생들은 교양 강의를 선택할 때 흥미 및 관심사를 가장 우선순위로 고려하였으며, 강의 제목의 모호함 때문에 강의에 대한 키워드가 가장 필요한 정보라고 응답하였다. 더불어 설문 응답자들은 원하는 강의와 원하는 수업 방식을 추천 결과에 직접 반영하고자 하는 요구를 확인하였다. 본 연구가 국내 대학 교육 실정에 맞는 인공지능 기반의 맞춤형 강의 추천 시스템을 개발하고 학습자에게 맞춤형 교육 정보를 제공하고자 할 때 기초자료로 기여할 수 있기를 기대한다.

주요어 : 인공지능, 추천시스템, 적응형 학습, 고등교육, 래피드 프로토타입 모형

[†] 교신저자 : 이진숙, 고려대학교, gupye@korea.ac.kr

I. 서 론

코로나 19와 디지털 가속화로 인한 현재 고등교육의 패러다임은 변화의 진통과 성장을 동시에 겪고 있다. 비대면 강의 전환에 따른 디지털 리터러시 격차, 온라인 강의 플랫폼의 불안정성 등 여러 문제점이 제기되기도 했지만 캠퍼스 대신 웹 브라우저에서 보내는 시간이 증가함에 따라 관련된 수많은 데이터가 축적되었다. 또한 교내에 적재된 데이터를 새롭게 바라보는 관점이 증가하면서 데이터 기반의 교육 서비스를 제공할 수 있는 자원을 확보할 수 있었다.

한편, 4차 산업 혁명 시대를 맞아 인공지능(Artificial Intelligence)기반의 서비스가 교육 분야에도 활발하게 접목되어 맞춤형 교육에 대한 수요가 증가하고 있다. 특히 적응형 학습 환경(Adaptive Learning Environment: ALE)은 이와 관련된 대표적인 교육 모델로 학습자 개인에게 적합한 맞춤형 지식을 전달하고, 학습 과정을 동적으로 지원하여 이를 원활하게 해주는 교육 모델을 의미한다. 이때 학습자의 요구나 선호도를 추론하기 위하여 학습자의 행동을 모니터링하고 해당 행동을 해석한다(Paramythis & Loidl-Reisinger, 2003).

인공지능은 적응형 학습의 추론 과정에서 알맞게 적용될 수 있다. 방대한 양의 데이터로부터 학습자 개인의 정보는 물론 과거의 학습 이력 및 패턴, 학습자의 관심사 등을 고차원의 벡터 공간에서 스스로 훈련하여 개인에게 맞는 정보를 제공할 수 있다. 대표적으로 학습자 프로파일링을 통한 강의, 교육 자료, 매체 등을 추천하는 추천 시스템을 꼽을 수 있다. 이는 적응형 교육 하이퍼미디어 추천 시스템(Adaptive educational hypermedia recommender system)이라고 칭하기도 한다(Brusilovsky, 2003).

Bloom(1984)은 2-Sigma 이론을 통해 1:1 맞춤형 교수법을 제공받았을 때 전통적인 교수법보다 평균 성적의 차이가 2 표준편차만큼 차이가 난다고 하였으며, 해당 연구는 개인화를 통한 적응형 학습의 효과를 나타낸다. 이처럼 학습자는 자신에게 맞는 학습 환경을 제공받음으로써 최적의 학습 경험을 이룰 수 있다(Montebello, 2018). 특히 융합적인 사고와 문제해결능력이 중요한 현대 사회에서 교양 교육과 자신의 전공 분야를 수렴한 지적 능력의 향상은 대학 교육이 나아가야 할 방향으로 강조되고 있다. 따라서 개인의 관심사를 반영하여 이를 지원할 수 있는 적응형 추천 시스템의 필요성이 요구된다.

그러나 여전히 인공지능을 활용한 적응형 추천 시스템에 관한 연구는 미미한 상황이다. 특히 국내의 강의 추천 시스템에 관한 연구는 소수의 연구만 진행되어왔다(김충일 외, 2015; 손기락 외, 2007; 유재준 외, 2020; 윤장혁, 2016). 해당 소수의 연구도 추

천 엔진으로 이용되는 알고리즘 개발에만 초점이 맞춰져 있으며, 개발부터 실제 적용 및 사후 추적 조사까지 일련의 모형을 이용해 진행한 국내 연구는 전무하다.

따라서 본 연구에서는 국내 대학 교육에 적합한 AI 기반 강의 추천 시스템의 구체적인 개발 과정을 래피드 프로토타입 모형을 통해 제시하고자 하였다. 또한 실제 교내 포털 웹사이트에 탑재하여 개인화된 추천 결과와 제공되는 정보에 대한 학습자의 반응을 설문조사를 통해 살펴보고자 하였다. 마지막으로 추천된 결과의 실효성을 파악하기 위하여 사후 추적 조사를 통해 해당 시스템의 유용성을 제시하고자 하였다. 해당 연구 목적을 달성하기 위한 구체적인 연구문제는 다음과 같다.

첫째, 래피드 프로토타입 모형은 개인화된 AI 기반 강의 추천 시스템 개발에 적합한가?

둘째, 개발된 AI 기반 강의 추천 시스템에 대한 사용자의 만족도는 어떠한가?

셋째, AI 기반 강의 추천 시스템을 이용한 학습자의 다음 학기 희망강의 등록 현황과 수강신청 결과는 어떠한가?

II. 이론적 배경

1. 추천 시스템(Recommender system)

추천 시스템은 통상적으로 이용자의 관심사를 반영하여 적합한 제품이나 서비스를 제안하는 기술을 의미하는 것으로 전자상거래, 동영상 스트리밍, 소셜미디어의 친구 추천 등 이미 우리 생활 전반에 깊이 자리하고 있는 대표적인 인공지능 기술이다. 전통적인 추천 시스템은 크게 협업 필터링(Collaborative filtering)과 내용 기반 필터링(Content-based filtering)으로 나뉘는데(윤장혁, 2016), 협업 필터링은 사용자와 아이템 간의 상호작용 패턴을 활용하여 높은 선호도를 가질만한 아이템을 추천해주는 방식이다. 내용 기반 필터링은 아이템의 내용이나 특징을 이용하여 이용자에게 유사한 아이템을 추천해주는 방식이다(Bobadilla et al., 2013).

1) 협업 필터링

협업 필터링이란 Tapestry 추천 시스템(Goldberg et al., 1992)에서 처음 언급되었는데 어떤 아이템이나 서비스에 있어 선호하는 정도가 비슷한 사용자들의 유사도를 측정하여 사용자가 아직 경험해보지 못한 아이템을 추천해주는 방식으로 정의한다(김충일

외, 2015; 윤장혁, 2016; Bobadilla et al., 2013). 협업 필터링은 크게 사용자 기반 필터링과 아이템 기반 필터링으로 다시 나뉜다. 사용자 기반 필터링은 목표 사용자와 선호 성향이 유사한 사용자의 평가에는 높은 가중치를 부여하고 선호도가 유사하지 않은 사용자에게는 낮은 가중치를 부여하여 추천 아이템을 선정하는 방식이다. 이를 강의 추천 시스템에 접목한다면 학습자와 유사하게 높은 평가를 준 주변 학습자가 수강했던 강의를 추천해주는 방식으로 볼 수 있다. 아이템 기반 협업 필터링은 사용자가 이미 구매하거나 소비한 아이템에 매긴 선호도를 이용하여 추천하고자 하는 아이템 사이의 유사도를 측정하여 제공하는 방법이다(김충일 외, 2015; 손기락 외 2007; 윤장혁, 2016; Pazzani, 1999). 이 또한 강의 추천 시스템에 적용한다면 학습자가 높게 평가한 강의가 있을 때 이와 유사한 강의도 높게 평가할 것이라 판단하여 유사한 강의를 추천해주는 방식으로 해석할 수 있다.

유사한 사용자나 아이템을 찾고자 할 때 Dudani(1976)가 제시한 K-최근접 이웃(K-nearest neighbor)알고리즘 등이 대표적으로 이용되는데 유재준 외(2020)과 손기락 외(2007)는 사용자 기반의 협업 필터링을 이용하여 유사한 사용자를 찾는데 해당 알고리즘을 이용하였다. 최근에는 고도화된 딥러닝 알고리즘을 이용하여 사용자의 선호도를 측정할 때 평가점수와 같은 가시적이고 명백한 활동만을 측정하는 것이 아니라 잠재적인 특성도 발견하여 추천 알고리즘을 개발하기도 한다(He et al., 2017; Hu et al., 2008).

2) 내용 기반 필터링

내용 기반 필터링은 아이템들의 특성을 추출하여 이와 유사한 아이템들을 사용자에게 추천하는 방식이다. 이 특성들은 정형 데이터 뿐만 아니라 텍스트나 음성 주파수와 같은 내용을 정의할 수 있는 비정형 데이터도 이용할 수 있다. 예를 들어 강의 개요와 같은 텍스트 데이터가 있을 때, 이를 형태소 단위로 분절하여 사람이 인지할 수 없는 고차원의 공간에 단어 벡터와 강의 벡터를 함께 임베딩하여 유사한 강의를 도출해내는 방식을 적용할 수 있다. 내용 기반의 알고리즘을 도출할 때는 함께 구매했거나, 듣거나, 방문했거나 시청했거나 혹은 함께 긍정적인 평가를 했을 때와 같이 공통된 사건이 포함되기도 한다(Bobadilla et al., 2013).

내용 기반 필터링은 사용자에 대한 정보가 없을 때 추천해줄 수 없는 콜드 스타트 문제(Cold-start problem)를 해결할 수 있는 하나의 방법이다. 김충일 외(2015)는 해당 문제를 보완하기 위하여 수강 과목 수에 따라 세 그룹으로 나누어 사용자 기반의 협업 필터링과 내용 기반 필터링을 혼합한 하이브리드 필터링 방식으로 교양 강의 추천 알

고리즘을 제시하였다.

2. 적응형 교육 하이퍼미디어 추천 시스템(Adaptive educational hypermedia recommender system)

교육 분야의 추천 시스템은 인공지능 태동기인 1960년대에서 70년대부터 꾸준히 언급되어왔으며, 개인화된 학습 추천에 대한 큰 발전이 이루어지면서 적응형 교육 하이퍼미디어 추천 시스템이라는 이름을 가지게 되었다(Montelbello, 2018).

Henze와 Nejd(2004)는 적응형 교육 하이퍼미디어 추천 시스템이 크게 4가지 요소로 구성된다고 하였다. 첫째, 학습자의 지식 기반에 이미 쌓여있는 정보나 지식이다. 이는 교수자가 직접 제공한 자료나 공공자원 또는 개인의 자원을 통해 축적된다. 둘째, 저장된 콘텐츠를 이용하여 개인화된 자료를 추천할 수 있는 추천 엔진 즉, 인공지능 기술이 반영된 알고리즘이다. 셋째, 개인에게 적합한 자료를 추천하기 위한 학습자 프로파일링이다. 마지막으로 학습자의 피드백이나 행동에 대한 결과를 발견할 수 있는 관찰방법이다. 적응형 학습은 학습자의 변화하는 지식 베이스와 정보에 따라 동적으로 변화하는 것이 특징이다. 따라서 시간이 지남에 따라 학습자 학습 과정에 맞는 주기적인 알고리즘 업데이트가 필요하고 이를 위한 모니터링이 필요하다.

종합하면 적응형 교육 하이퍼미디어 추천 시스템은 정교한 학습자 프로파일링으로부터 이루어진다. 이를 통해 학습자의 관심사를 꾸준히 포착하고 다양한 프로파일을 가진 학생들의 요구에 맞는 교수 설계를 진행할 수 있다. 전통적인 방식에서 모든 학생들의 요구를 반영하기 위한 교수 설계는 불가능에 가깝다. 그러나 개인에게 맞는 학습자 프로파일링이 완료되어 훈련된 인공지능 기반의 교육 추천 시스템은 교수자의 교수 설계에 도움이 될 뿐만 아니라 학습자가 직면한 제각기 다른 복잡한 학습 상황에서 최적화된 학습 환경을 지원할 수 있게 된다(Montelbello, 2018).

3. 대학 교육의 인공지능 기반 추천 시스템

최신 IT 관련 기술이 빠르게 발전하고 변화가 가속화됨에 따라 적응형 학습에 관련된 연구가 증가하고 있으며, 실제 인공지능 기술을 교육 분야에 적용하여 학습자의 의사결정 지원을 돕고 있는 사례가 등장하고 있다. 대표적인 사례로 Stanford University의 “Carta”는 학습자의 요구에 맞게 손쉽게 강의를 검색하고 관련 데이터를 통해 의사결정을 지원하는 플랫폼이다. 학습자는 Carta를 통해 수업 기본정보, 난이도, 평균 학습 시

간, 이수율, 학년별 비율, 타 수업과의 조합별 수강생 비율, 해당 강의 이전에 수강한 강의, 동시에 수강한 강의, 이후에 수강한 강의 등을 확인할 수 있다.

Carta는 강의 수강 경로 및 수강 신청에 대한 연구를 바탕으로 개발되었다. 스탠포드 대학교 재학생의 강의 수강 경로 패턴을 네트워크로 나타내고 중심성 분석을 통해 강의의 역할을 규명하였다(Angus et al., 2019). 또한 단과대별 수강 신청 데이터를 이용하여 학생들의 수강신청 현황과 순서 데이터를 딥러닝 모델에 적용하여 잠재적인 변수를 발견하고 이에 따라 강의를 분류하고 추천하였다(Gruver et al., 2019).

또한 해당 플랫폼에서 기록되는 로그 데이터와 신입생과의 인터뷰를 통해 적응형 교육 추천 시스템의 방향성을 제시하였는데 Carta 이용을 통해 강의 선택에 있어 좁아진 시야를 넓힐 수 있고 지엽적인 강의 탐색이 언제 이루어지는지 알 수 있다고 하였다. 또한 추천되는 강의는 STEM분야에서 다소 집중을 받지 못했던 여성집단이나 학습 위기에 처한 집단에 도움이 될 것이라고 하였다. 마지막으로 미국 중등교육 이후 가장 시급한 문제인 중도탈락률 완화의 방안으로 이용될 수 있다고 제시하였다(Chaturapruek et al., 2021).

더불어 Carta가 학습자의 학업 성취도에 영향을 미쳤는지에 대한 후속연구도 진행하였는데 해당 프로그램을 사용하였을 때 학습자의 성적 분포의 표준편차가 0.28 감소하였으며, 해당 강의에 성적 분포를 제시하였을 때 이를 참고한 학생들의 평균적인 성적이 감소하여 정보 제공 정책에 대한 논의가 필요하다는 것을 밝혀내었다(Chaturapruek et al., 2018).

한편 UC Berkeley는 딥러닝 기술 중 자연어 처리에 많이 이용되는 모델의 원리인 잠재 의미 분석 알고리즘을 강의 추천 시스템에 적용하였다. 순환신경망 모델인 RNN(Recurrent Neural Network)과 자연어 처리 모델을 이용하여 추천 엔진을 구현하였고, 교내 포털 사이트에 강의 탐색, 강의 추천 기능을 추가하고 설문조사를 진행했다(Pardos et al., 2019; Shao et al., 2021). 또한, 이를 바탕으로 한 강의 지도를 제작하였다(Pardos & Nam, 2020). 그러나 해당 연구도 래피드 프로토타입과 같은 교수 설계 모형을 적용하여 연구되지는 않았으며, 알고리즘 개발에 초점이 맞추어져 있다.

국내의 연구에서는 강의 추천 시스템 연구와 관련하여 주로 추천 엔진을 구현하는 연구가 종종 진행되어왔지만(김충일 외, 2015; 손기락 외, 2007; 유재준 외, 2020; 윤장혁, 2016) 다른 분야의 추천 시스템에 연구가 활발한 것에 비해 대체로 샘플의 크기가 작고 기초적인 수준의 협업 필터링 알고리즘을 적용한 연구가 대다수이며, 실제 적용과 설문조사 및 사후 추적 조사까지 이루어진 경우는 전무하다.

따라서 교육 분야의 추천 시스템에 관한 연구의 필요성을 느끼는바, 본 연구에서는

기존의 협업 필터링 알고리즘과 수강 이력 기반의 알고리즘을 개발하고 Carta와 같은 강의에 관련된 정보를 제공하는 AI 기반 강의 추천 시스템을 구축하고자 하였다. 더불어 적응형 교육 하이퍼미디어 추천 시스템의 마지막 요소인 학습자의 피드백과 이용 행동을 관찰하기 위하여 전반적인 서비스 만족도 설문조사와 실제 학생들의 희망 강의 등록 및 수강 신청 데이터 분석을 하였다.

III. 연구 방법

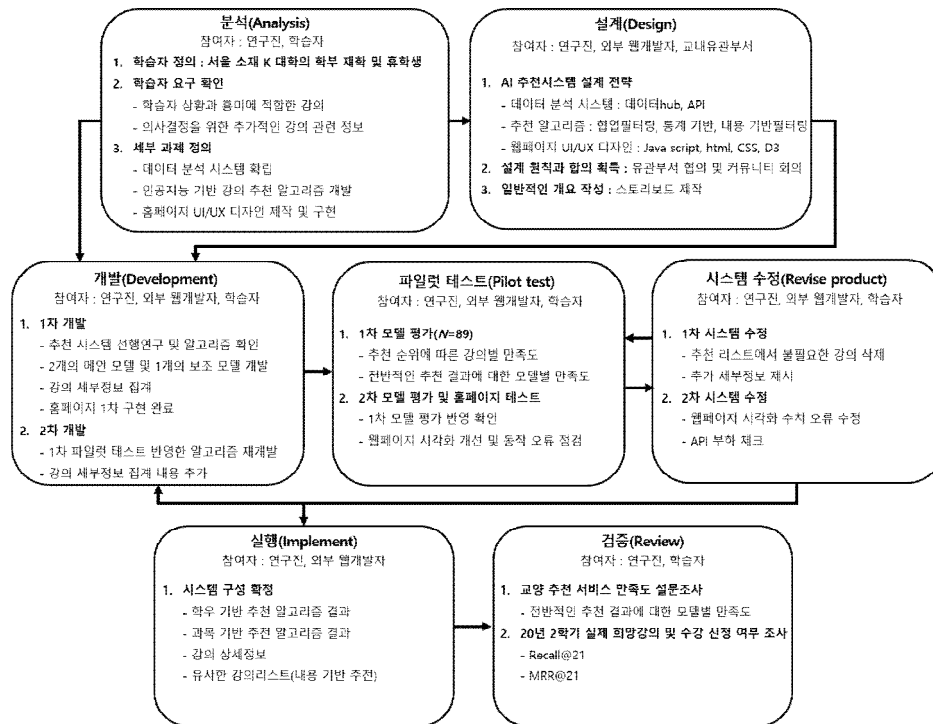
1. AI 기반 추천 시스템 개발 절차

교육 현장에 적용하기 위한 AI 기반의 추천 시스템 설계는 Jones와 Richey(2000)가 제시한 래피드 프로토타입(Rapid prototyping methodology; RP) 설계 방법을 활용하였다. 래피드 프로토타입 개발 모형은 전통적인 ADDIE 교수-학습 설계 모형에서 제시하는 세부 단계인 ‘분석(Analysis)’, ‘설계(Design)’, ‘개발(Development)’, ‘실행(Implementation)’, ‘평가(Evaluation)’와 크게 다르지 않으나 비선형적인 개발 과정을 거친다는 점에서 전통적 모형과 차이를 보인다(임철일 외, 2005). 또한, 사용자가 직접 개발의 과정에 참여하여 고유한 역할을 수행할 수 있는 특징이 있다. 개발 과정에 포함된 대부분 단계가 중첩되어 동시에 이루어지고 중간 산출물 검토 과정을 한번 거치기 때문에 전체 개발 과정 시간을 단축할 수 있는 장점이 있다(Jones & Richey, 2000).

래피드 프로토타입 개발 방법은 웹 기반의 프로그램을 고안하는 데 적합한 방법론이다. 웹 기반의 프로그램을 개발하는데 전통적인 설계 모형에 따르게 되면 학습자가 최종 결과물을 접하게 될 때까지 상당한 시간이 소요될 뿐만 아니라 교수자가 이를 수정하는데도 어려움이 따르기 때문이다. 따라서 래피드 프로토타입 개발 모형을 적용하여 학습자와 사용자의 초기 단계의 개입을 통해 수정 및 보완 과정을 거치고, 최종안을 도출하는 것이 효율적이다(임철일 외, 2005).

본 연구에서 개발하고자 하는 대학에서 제공하는 AI 기반의 추천 시스템도 하나의 교육용 소프트웨어 프로그램으로 간주할 수 있으며, 학습자들이 손쉽게 웹에서 이용할 수 있도록 설계하고자 한다. 더불어 K 대학의 2020년 2학기 수강신청 일정보다 1주일 앞선 시기에 서비스를 공개하기 위하여 래피드 프로토타입 방법론을 활용하였으며, AI 기반 추천 시스템 설계 및 개발과 적용 및 평가 단계를 거쳤다. 또한 래피드 프로토타입은 다른 교수 설계 모형과 달리 사용자가 개발의 단계에서부터 참여하는 특징을

갖고 있고 인공지능 기반의 새로운 시스템을 구축할 때는 사용자의 정확한 요구 파악이 중요하므로 해당 방법론을 선택하였다. [그림 1]은 해당 개발 방법론을 본 연구의 개발-활용-평가 모형으로 도식화한 것이다. 각 단계의 세부 절차는 다음과 같다(그림 1 참조).



[그림 1] AI 기반 추천 시스템 개발-활용-평가 모형

1) 분석(Analysis)

래피드 프로토타입 방법론의 첫 번째 단계는 ‘분석(Analysis)’ 단계이다. 해당 과정은 ‘학습자 정의’, ‘학습자 요구 확인’, ‘세부 과제 내용 정의’의 하위 세부 3가지 단계로 구분할 수 있다(Jones & Richey, 2000). 이때 참여자는 본 연구의 연구자인 데이터 사이언티스트 2명, 데이터 엔지니어 2명, 총괄자 1명의 연구진과 외부 웹 개발자 2명, 실사용자인 학습자 이루어졌다. 각각의 세부 절차는 다음과 같다.

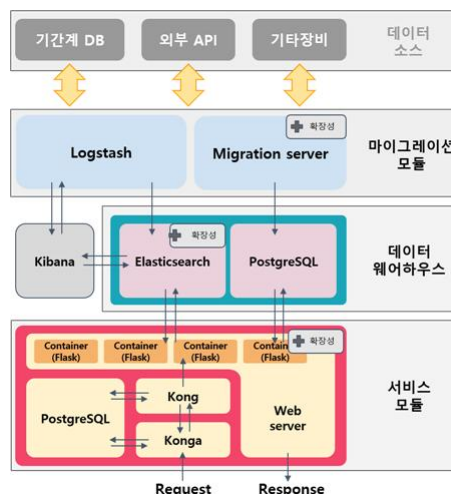
첫째, 학습자 정의 단계에서는 국내 K 대학 서울캠퍼스 2020학년도 1학기 재학생을 대상으로 하였다. 둘째, 학습자 요구 확인 및 단계에서는 교내 전문가, 유관부서, 교내 재학생과의 인터뷰를 통하여 추천 서비스 범위를 설정하였다. 학생 수요가 높고 주어

진 시간 안에 기술적 구현 가능성이 큰 교양 강의 추천 시스템 구현으로 목표를 설정하였다. 마지막으로 대학의 AI 기반 교양 강의 추천 시스템 구현을 위하여 다음과 같은 세부 과제 내용을 데이터 분석 시스템 확립, 교양 강의 추천 모델 엔진 개발, 홈페이지 UI/UX 디자인 및 제작 구현의 단계로 정의하였다.

2) 설계(Design)

래피드 프로토타입 개발 방법론의 두 번째 단계는 ‘설계(Design)’ 단계이다. 이 과정에서는 ‘AI 추천 시스템 설계 전략’, ‘설계 원칙 작성과 합의 획득’, ‘일반적인 개요 작성’의 세부 3가지 단계로 구분된다(Jones & Richey, 2000). 해당 단계의 참여자는 연구진, 외부 웹 개발자 2인 구성으로 이루어졌다. 각 세부 단계의 내용은 다음과 같다.

첫째, AI 추천 시스템 설계 전략은 분석 단계의 세부 과제 내용에 따라 구성하였다. 먼저 AI 교양 강의 추천 시스템 서비스에 이용될 분석 시스템을 확립하기 위하여 본 연구에서는 교내에서 자체 구축한 데이터 Hub를 활용하였다. 본 연구에서 이용된 데이터 Hub는 마이그레이션 모듈(Migration module), 데이터 웨어하우스(Data warehouse), 서비스 모듈(Service module) 아키텍처로 구성되어있다. [그림 2]는 데이터 Hub의 전체적인 구조를 도식화하여 나타낸 것이다(그림 2 참조).



(그림 2) K 대학의 데이터 Hub 구조

더불어 본 연구의 연구자인 데이터 사이언티스트와 교내 인공지능 전문 연구진이 사용자 기반의 협업 필터링 알고리즘(User-based collaborative filtering)을 활용한 알고리즘,

통계 기반의 알고리즘, 비정형데이터 기반 유사 강의 추천 알고리즘을 개발하였다. 해당 방법론은 본 연구의 핵심 구성 요소이므로 2절에서 상세히 다루고자 한다.

홈페이지 UI/UX 디자인 및 구현 단계에서는 연구팀의 데이터 엔지니어와 외부 웹 개발자가 참여하여 AI 추천 시스템의 웹 페이지를 구현하였다. 스프링 프레임워크(Spring Framework)를 기반으로 자바스크립트(JavaScript), HTML(Hyper Text Markup Language), 그리고 CSS(Cascading Style Sheets)로 구성하였다. 데이터 Hub의 데이터 웨어하우스에 접속하고 데이터 교환 작업을 하기 위해 JDBC(Java Database Connectivity)를 사용하며, 웹서버는 톰캣(Tomcat)을 사용한다.

둘째, 설계 원칙 작성과 합의 획득 단계에서는 개발된 모델의 퍼포먼스에 따라 기본적인 서비스의 품질이 결정되기 때문에 모델의 성능과 설계팀이 제공하고자 하는 교육용 시스템으로서의 방향성을 논의하기 위하여 커뮤니티를 구성하고 월 2회 정기적인 회의를 진행하였다. 커뮤니티 참여자는 앞서 언급한 설계팀을 비롯한 인공지능 참여 연구진과 함께하였으며, 격주로 대면 및 비대면 회의를 통해 진행 상황을 공유하고 개선점을 도출하였다. 또한 교내의 유관부서와 서비스에 대한 타당성을 검토하고 공개 가능한 데이터의 수준을 합의하였다.

마지막으로 일반적인 개요 작성 단계에서는 나일주와 정현미(2001)의 연구를 참고하여 연구진이 제공하고자 하는 UI/UX 홈페이지 시안을 Powerpoint을 이용한 스토리보드를 제작하여 웹개발자와 해당 시안에 대한 상호작용을 진행하였다. 웹 개발자는 최종 퍼블리싱 형태의 HTML 파일을 페이지별로 제작하여 구현한 웹 페이지를 공유하고 개선점을 논의하고 수정하였다.

3) 개발(Development)

설계 단계에서 확립된 교양 추천 알고리즘을 개발하기 위하여 1차 개발 시 추천 시스템과 관련된 선행연구 및 알고리즘을 확인하였다. 총 3개의 추천 알고리즘을 선정하였고 그 중 내용 기반의 비정형 데이터를 활용한 유사 강의 추천 알고리즘은 사용자마다 다른 추천 결과가 나오지 않으므로 별도의 파일럿 테스트 없이 시스템에 반영하기로 결정하였다. 더불어 추천된 강의를 클릭하였을 때 관련된 강의 정보를 제공하기 위하여 학년별 분포, 전공별 분포에 대한 집계 작업도 수행하였다. 마지막으로 웹 개발자로부터 획득한 HTML 시안을 활용해 최종적인 웹 페이지 UI/UX 구축을 마무리하였다.

2차 개발에서는 1차 모델 평가를 바탕으로 알고리즘 수정을 진행하였다. 또한 강의의 세부정보에는 학년별 분포, 전공별 분포와 더불어 해당 강의에 지정된 핵심 역량

수치도 포함하였다.

4) 파일럿 테스트(Pilot test)

1차 파일럿 테스트에서는 본 연구에서 개발하고자 하는 프로그램의 핵심인 추천 모델 2가지에 대하여 사전의 파일럿 테스트 응답자를 모집하였다. 파일럿 테스트를 통하여 실사용자의 의견을 반영하고 시스템 수정 작업과 함께 최종 알고리즘을 선정하고자 하였다. 설문 응답자는 각 추천 알고리즘별로 20개의 맞춤형 추천 강의 리스트를 받았으며, 추천된 강의에 대한 만족도와 추천 알고리즘별 만족도를 평가하였다. 만족도는 알고리즘 자체에 대한 만족도와 알고리즘이 추천해주는 강의에 대한 만족도를 5점 리커트 척도(Likert Scale) 구성하였다(<표 1> 참조). 파일럿 테스트에는 총 89명의 본교 재학생이 참여하였으며, 이를 통한 알고리즘의 사전 검증과 알고리즘 정확도를 개선하였다.

〈표 1〉 파일럿 테스트 만족도 설문 문항 구성

요 소	하위요소	평가내용	문항수
모델 평가	추천된 강의	추천된 강의별 만족도	40
	추천 모델	추천 모델별 만족도, 모델에 대한 의견(서술형)	4

2차 파일럿 테스트에서는 1차 파일럿 테스트 결과가 반영된 모델 결과와 웹페이지 시각화 개선본을 재검토 하였다.

5) 시스템 수정(Revise product)

1차 시스템 수정에서는 파일럿 테스트를 통해 도출해 낸 사용자의 의견은 크게 추천 모델의 기능과 웹 페이지 구현의 오류로 나뉘었다. 해당 추천 모델의 기능 개선은 모델의 2차 개발로 수행되었으며, 그 밖의 웹페이지 강의 세부페이지의 가독성을 높이기 위하여 불필요한 문구들은 삭제하고 도표 배치 작업을 수행하였다. 또한, 해당 상세정보는 유관부서와 협의하여 공개 가능한 데이터 범위를 바탕으로 강의와 관련된 정보를 제시하였다.

2차 시스템 수정에서 알고리즘 수정과 홈페이지 수정을 마친 최종 점검을 진행하였다. 추천 결과는 API 호출을 통한 실시간 제공 방식과 데이터 배치 테이블 제작 후 JDBC를 통한 제공 방식 두 가지를 준비하였지만, 시스템 안정성을 위해 후자를 선택하였다.

6) 실행(Implement)

본 시스템은 용이한 접근성, 개인정보 유출의 우려, 학적 정보 연동 등을 고려하여 교내의 포털 사이트에 탑재하였다. 사용자는 포털 로그인을 통해 해당 서비스에 접근할 수 있도록 하였다. 또한 포털 로그인시 팝업창을 띄워 새로운 서비스가 추가되었음을 안내하였다. 이 시스템의 이용자인 학습자는 자신에게 맞는 2가지 추천 리스트를 안내받으며 해당 강의에 대한 상세정보를 확인할 수 있고 그 강의와 유사한 강의 리스트도 제공받을 수 있다.

7) 검증(Review)

본 연구에서 해당 서비스에 대한 검증은 2가지로 이루어졌다. 첫째, 본 연구에서 개발한 서비스에 대한 만족도 설문 문항을 구성하고 주기적으로 실사용자의 피드백을 분석하고자 하였다. 서비스 첨부용 만족도 설문 문항의 구성은 <표 2>와 같다. 본 설문문에 포함된 모델 평가 요소는 주메뉴로 선정된 협업 필터링 모델과 통계 기반 모델 1가지에 대하여 문항을 구성하였다. 본 서비스 만족도 설문은 2020년 7월부터 9월까지 3개월 동안 추천 서비스 웹 페이지에 구글 설문지 링크를 첨부하여 진행하였다.

〈표 2〉 서비스 만족도 설문 문항 구성

요 소	하위요소	평가내용	문항수
강의 수강	고려요인	교양 강의 선택 시 주요 고려요인	2
	정보	교양 강의 선택 시 필요한 정보	
모델 평가	모델	추천 모델별 만족도	2
기능 및 방향성	희망 기능	추가 희망 추천 기능	2
	방향성	희망하는 추천 준거	
기타	기타 의견	추천 서비스 전반에 대한 의견 및 건의 사항(서술형)	1

둘째, 사용자가 만족한 추천 결과가 실제 행동으로 이어졌는지 알아보기 위하여 본 추천 시스템을 이용한 후 응답한 학생들이 실제로 이후의 학기에 추천된 교양 강의가 희망 과목 리스트 및 수강 이력에 포함되었는지 확인하고자 하였다. 이용한 지표는 Recall과 MRR(Mean Reciprocal Rank)으로 Recall은 주어진 추천리스트에서 평균적으로 몇 개의 강의를 수강했는지를 나타내는 지표로 <식 1>와 같다. MRR은 순위를 고려한 지표로 수강한 강의가 추천리스트가 리스트의 몇 번째에 등장했는지 측정할 수 있는 지표로 <식 2>와 같이 계산한다(Pardos et al., 2019).

$$Recall = \frac{1}{|S|} \sum_{i=1}^{|S|} \frac{|courses_i \cap recommended_i|}{|courses_i|}$$

[식 1] Recall 공식

$$MRR = \frac{1}{|S|} \sum_{i=1}^{|S|} \frac{1}{rank_i}$$

[식 2] MRR(Mean Reciprocal Rank) 공식

본 사후 추적 조사에 포함된 대상자는 설문조사에 참여한 782명 중 2020년도 2학기에 교양 강의를 신청한 87명과 교양 강의를 희망과목으로 등록한 445명의 수강이력 및 희망 과목 등록 내역을 이용하여 Recall@21과 MRR@21을 측정하였다.

8) 개발 일정

<표 3>은 임철일 외(2005)의 연구를 참고하여 AI 기반 추천 시스템 개발을 위한 일정과 Jones와 Richey(2000)가 제시한 분석 절차를 함께 나타낸 표이다. 시스템 개발 및 적용은 2020년 3월부터 12월까지 진행되었으며, 해당 작업이 진행된 달에는 음영으로 표기하였다. 같은 시기에 음영 처리가 겹쳐있을 때에는 해당 단계가 중첩되어 진행되었음을 뜻한다. 또한 참여자의 관여 정도에 따라 중첩원과 원으로 표시하였다.

2. 교양 강의 추천 알고리즘

본 연구에서는 사용자 기반 협업 필터링 모델(김두형 외, 2020), 과목 분포에 따른 통계 기반 모델, 내용 기반의 모델 3가지를 구현하고자 하였다. 각각의 구현 과정은 다음과 같다.

1) 사용자 기반 협업 필터링

(1) 이용 데이터

사용자 기반 협업 필터링에서 이용된 데이터는 입학 년도가 2013년도에서 2020년도에 해당하는 K 대학의 재학생 및 졸업생 33,781명의 데이터를 이용하였다. 교내 데이터 베이스에 적재된 이들의 2013년도에서 2020년 1학기까지의 수강 이력 1,980,157건과 수강한 강의에 대한 수강 평가 데이터를 이용하였다. 2013년도부터 2020년까지의 수강 소감 평가 문항이 일치했기 때문에 해당 범위로 설정하였다. 학번의 경우 비식별화 처

〈표 3〉 AI 기반 강의 추천 시스템 래피드 프로토타입 단계별 개발 일정

RP 단계	세부 단계	추진 일정(월)												참여자	
		3	4	5	6	7	8	9	10	11	12	연구진	외부 개발자	사용자	
분석	학습자 분석												◎		
	학습자 요구 확인												◎		○
	목표 설정												◎		
	세부 과제 내용 정의												◎		
설계	AI 시스템 설계 전략												◎		
	설계 원칙 작성, 합의												◎	○	
	일반적인 개요 작성												◎	◎	
개발 & 프로토타입 타입	추천 모델 개발												◎		
	상세 정보 수집												◎		
	웹 페이지 개발												◎	◎	
	설문조사 문항 개발												◎		
	파일럿 테스트												◎		◎
전달	시스템 수정												◎	◎	◎
	콘텐츠 확정												◎		
	추천 결과 저장												◎		
	포털 웹 탑재												◎	◎	
	권한 부여												◎	○	
실행	본 서비스 시행												◎		◎
평가	만족도 설문조사												◎		◎
	사후 추적 조사												◎		

*참여도 ◎ : 높음, ○ : 보통

리하여 모델 개발에 이용하였다. 수강한 강의에 대한 평가 데이터의 경우 해당 기간의 데이터는 1점~6점 리커트 척도로 수집되어 있었다.

(2) 점수식 정의

협업 필터링에서 선호도로 측정되는 평가 점수는 모델이 예측하고자 하는 점수이며 얼마나 실제 선호 점수와 가깝게 예측하였는지에 따라 모델의 성능이 좌우된다. 본 협업 필터링 모델에서는 수강 평가 데이터와 학생이 속한 학과를 반영한 점수식을 예측하고자 하였다. 점수식은 [식 3]과 같다. 이는 해당 학과에서 인기가 많은 강의에 대한

평가 점수에 가중치를 부여할 수 있으며 매번 변경되는 졸업 요건을 반영할 수 있는 방법이다. 수강 평가 점수에서 평균 수강 평가 점수를 뺀 이유는 벡터의 각도를 이용한 코사인 유사도를 활용하기 때문이며 한 강의에 대해 1점을 준 학생과 5점을 준 학생의 차이를 분명하게 하기 위함이다.

$$score_A = \frac{\text{해당 학과에서 발생한 } A \text{ 강의의 수강건수}}{\text{해당 학과의 전체 교양수강건수}} \times (\text{수강평점}_A - \text{평균수강평점}_A)$$

[식 3] 점수식 정의

수강 이력을 나타내는 데이터의 여러 컬럼 중 성적을 나타내는 데이터도 수집할 수 있었으나, 성적을 점수식에 포함하게 되면 한 학생이 성적을 잘 취득할 수 있는 강의로만 추천하게 된다. 이는 편향된 추천 결과를 제공할 수 있으며, 다양한 강의를 탐색할 수 있는 기회를 제공하기 위한 시스템 개발 목적에 부합하지 않는다. 더불어 성적을 강의 추천 모델에 포함시켰을 때 추천의 결과가 향상되지 않았다는 Shao 외(2021)의 선행연구를 참고하여 본 연구에서는 성적 데이터를 이용하지 않았다.

(2) 코사인 유사도 계산

추천 시스템의 이용 사용자와 유사한 사용자를 도출하기 위해 피어슨 상관계수, 코사인 유사도, 맨하탄 유사도, 자카드 유사도 등 여러 가지 유사도 측정 방법을 이용한다. 본 연구에서는 전통적으로 널리 쓰이는 코사인 유사도를 이용하였다(Bobadilla et al., 2013; Lu et al., 2015). 코사인 유사도의 벡터의 길이와 상관없이 각도를 기준으로 유사도를 측정하는 방식이다. 해당 공식은 [식 4]과 같다.

$$similarity = \frac{A \cdot B}{\|A\| \|B\|}$$

[식 4] 코사인 유사도 공식

(3) K-최근접 이웃법

유사도를 계산한 이후 K-최근접 이웃법(K-Nearest Neighbor)를 이용하여 유사한 K명의 이웃을 구했다. K-최근접 이웃법이란 목표 사용자의 가장 근접한 거리에 있는 K명의 사용자 정보를 이용하는 방식으로(손기락 외, 2007), 본 알고리즘에서는 학과별로 학과마다 정원이 다르므로 통일된 K명의 유사한 사용자를 찾을 경우 너무 지역적인 추천이나 광범위한 추천이 이루어질 수 있어(김충일 외, 2015) 학과마다 다른 최적의

K를 산출하였다. 또한 같은 학과여도 매학기 수강신청 인원 역시 상이한 것을 고려하여 최적의 K는 절대적인 숫자가 아닌 상대적인 비율로 산정하여 도출하였다. 학과별로 다른 최적의 K를 구하기 위하여 2020년 1학기 기준으로 재학 중인 3학년과 4학년 학생 중 2019년 1학기까지의 데이터로 학습한 모델이 추천해준 결과가 2020년 1학기에 수강한 강의가 얼마나 포함되어 있는지 평균 비율 즉 Recall을 계산하여 가장 높은 Recall값을 최적의 K로 정의하였다.

2) 과목 기반 추천 모델

본 연구의 과목 기반 추천 모델은 통계 기반의 자체 개발 알고리즘으로 위 2가지의 모델의 보완을 위해 제시된 알고리즘이다. 원리는 다음과 같다.

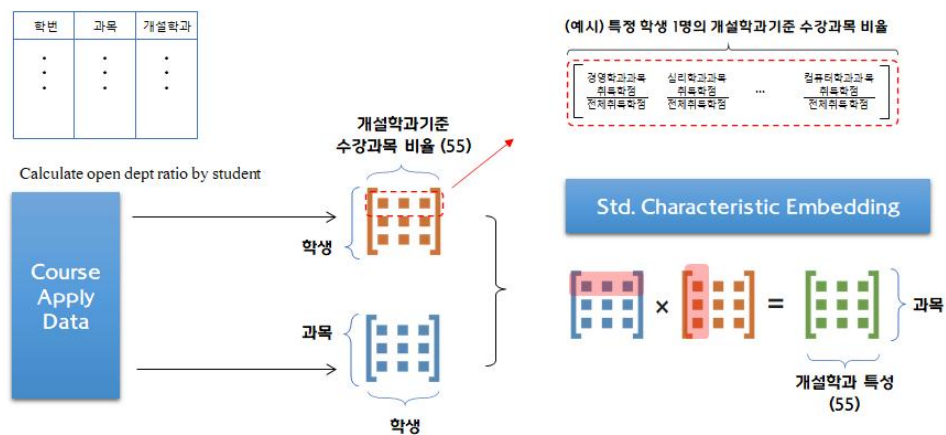
(1) 이용데이터

해당 모델 개발에 이용된 데이터는 수강 이력으로 K 대학의 2020년 1학기 기준으로 2011년에서 2020년까지의 재학생 및 졸업생이 수강한 전체 과목에 대한 데이터로 총 2,847,702건으로 수집되었다.

(2) 데이터 전처리 및 행렬 생성

수강생 특성 행렬은 각 과목 수강생의 수강 이력을 통해 과목별 수강생 특성 행렬을 제작하였다. [그림 3]은 그 과정을 도식화 한 것이다.

첫째, 개설학과별 수강 비율을 산출하기 위하여 한 학생이 이수한 전체 학점에서 특



(그림 3) 과목별 강의내용 차원 임베딩 개요

정한 학과에서 이수한 학점의 비율을 통해 학생별 수강이력 특성 행렬을 산출한다. 즉, 학생별 수강이력 특성 행렬은 학생이 행이 되고, 각 개설학과가 열이 된다. 이러한 연산을 1학년, 제적 및 입학 취소, 자유전공학부, 의예과, 의학과를 제외한 모든 학생들에 대해 실시하였다. 그 결과 39,141명의 학생이 55개 학과에서 수강한 비율 행렬이 생성되었다.

둘째, 이렇게 산출된 학생별 수강 비율을 활용해 과목별 수강생 특성을 산출했다. 특정 과목을 수강한 학생들의 각 학과별 수강 비율의 평균을 통해 산출하였다.

(3) 추천 알고리즘

수강생의 수강이력을 통해 산출한 수강생 특성 행렬과 학생의 수강 이력을 이용하여 과목 기반 교양 과목 추천 모델을 제작하였다. 학생들의 수강이력과 2020년 2학기 개설 예정인 교양 강의 사이의 유사도를 산출하였다. 수강생 특성 매트릭스를 기반으로 강의 간 코사인 유사도를 산출하였다(식 3). 그 다음 학생별 수강한 강의당 유사도 상위 N 개 강의를 추출한다. 이 때 N 값이 클수록 넓은 범위의 추천이 이루어지고 N 값이 작을수록 세부적인 범위의 추천이 이루어진다. 서비스에 적용된 N 값은 3, 5, 10이 적용되었다.

3) 내용 기반 추천 모델

(1) 이용 데이터 및 데이터 전처리

유사한 교양 강의를 안내하기 위한 내용 기반 추천 모델은 2013년부터 2020년까지 개설된 1,637개 강의에 대한 강의계획서, 강의별 교수요목 비정형 데이터를 이용하였다. 비정형 데이터에는 총 14,101개의 서로 다른 명사가 존재하였다.

먼저 14,101개의 서로 다른 단어에 대한 불용어 사전을 제작하였다. 전체 텍스트에서 500번 이상 등장한 어휘 중 “강의”, “계획”, “중간고사” 등 강의 내용과는 무관하게 보이는 어휘를 110개 선별하고 이에 해당하는 어휘는 제거하였다.

(2) FastText

내용 기반 추천 모델은 사용자가 이전에 경험한 아이템과 내용적으로 유사한 아이템을 추천해주는 방식이다. 모델 구현에 사용된 알고리즘은 FastText라는 사전 학습된 모델(Mikolov et al., 2017)을 이용하였다. FastText는 Facebook에서 2016년에 개발한 자연어처리 알고리즘으로 단어의 형태학적인 특성을 반영한 알고리즘이다. 본 시스템에서는 유사도가 80%이상일 경우에만 유사 강의 목록에 포함되도록 설계하였다.

IV 연구 결과

1. AI 기반 추천 시스템 개발

1) 분석(Analysis): 학습자 요구 확인 결과

학습자의 요구 확인을 위하여 강의를 선택할 때 고려하는 점, 어려운 점, 도움을 받았으면 하는 부분 등 수강 전반에 관련된 FGI(Focus Group Interview) 인터뷰 및 In-depth 인터뷰를 진행하였다. 수강 경험이 있는 학생들을 고려하여 학년은 고학년으로 선정하였으며, 교내의 졸업 요건인 제2전공 제도에 진입한 학생만을 선정하여 진행하였다. 인터뷰 대상자는 7인으로 2020년 3월 3일부터 23일까지 총 4회에 걸쳐 진행되었다. 인터뷰 방식은 대면, 비대면 모두 진행하였다. 인터뷰 요약 내용은 <표 4>와 같다.

〈표 4〉 학습자 요구 확인 인터뷰 요약

회차	일시	인터뷰 대상자	요약
1	2020. 3. 3	소프트웨어벤처 제2전공 이수자 3인	진로에 따른 과목 추천 필요 커리큘럼에 포함된 강의가 너무 많아 어떤 강의를 수강해야 도움이 될지 모르겠음
2	2020. 3. 19	생태진화생물학 제2전공 이수자 1인	5년 이상 개설되지 않는 강의는 다른 강의로 대체할 수 있는 제도가 필요하고 대체 가능한 강의를 알고 싶음 관심 있는 분야와 관련된 강의는 대체로 교수님 홈페이지에서 관련 강의 및 논문을 확인하거나 선배에게 자문을 구하곤 하는데 여전히 한계가 있음
3	2020. 3. 23	인적자원개발학 제2전공 이수자 1인	어떤 강의가 역량 개발에 도움이 되는지 확인하고 싶음 다른 학과 학생들은 어떻게 수업을 듣고 있는지 궁금함 제2전공을 위한 커뮤니티 같은 소통창구가 필요함
4	2020. 3. 23	인적자원개발학 제2전공 이수자 2인	제2전공을 이수한 선배가 자발적으로 개최한 설명회가 가장 도움이 많이 되었음 선수과목에 대한 정보와 수강정보를 알려주면 도움될 것 같음

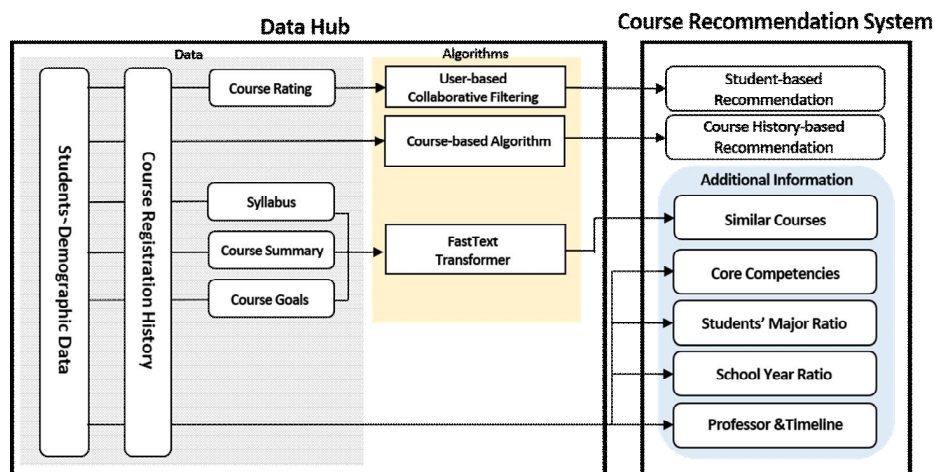
인터뷰 응답을 살펴보면 전반적으로 학교 홈페이지에서 얻을 수 있는 정보는 학과별 개설 강의 선에서 그치는 것을 알 수 있었다. 커리큘럼이 제시되어 있지만 어떤 강

의가 자신에게 적합할지와 원하는 진로에 도움이 될지에 대한 정보를 얻고자 하는 요구가 존재함을 확인하였다. 또한 강의와 관련된 정보를 얻는 출처는 학교 홈페이지 외에 선배가 자주 등장하였는데, 이는 선배와의 유대관계가 약한 학생들에게는 정보를 얻을 수 있는 한계가 존재한다는 것을 의미하며 선배를 대면해야지만 얻을 수 있던 정보 습득의 기회는 코로나 상황으로 인해 물리적인 접점이 줄어들어 어려움을 겪고 있을 것이라고 해석할 수 있었다.

따라서 본 연구에서는 학생에게 적합한 강의를 추천해주는 맞춤형 AI기반 추천 시스템을 구현하고 그와 함께 유용한 정보를 제공해주는 프로그램을 개발하는 것으로 목표를 설정하였다.

2) 설계(Design): AI 추천 시스템 구조도

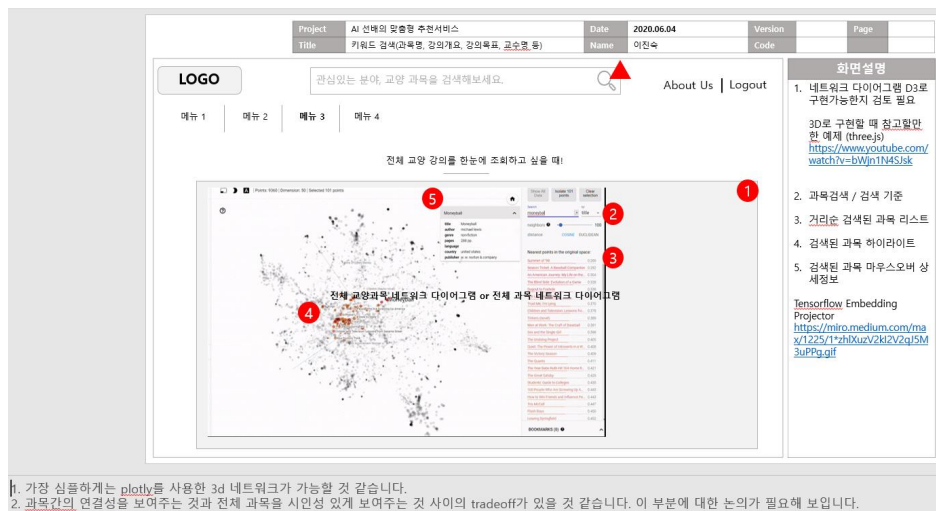
[그림 4]는 전체 AI 기반 추천 시스템의 구조도이다. 데이터 Hub에 적재되어 있는 학적정보, 수강 이력은 각 서비스 모듈의 공통된 데이터로 이용되었으며, 수강 소감 평가 데이터가 추가로 포함된 사용자 기반 협업 필터링 모델을 이용하여 나온 추천 결과는 “학우 기반 추천”이라는 이름의 서비스 모듈로 생성하였다. 또한 학생들의 수강 이력 데이터를 이용하여 “과목 기반 추천” 서비스 모듈을 생성하였다. 강의 상세정보에는 강의계획서 비정형 데이터와 교수요목 및 학습 목표 텍스트 데이터를 기반으로 한 “유사 강의 추천”모듈과 강의별 성취 가능한 핵심역량, 제1전공 및 제2전공 구성 비율, 학년별 비율, 교수자, 시간표, 강의실 정보를 제공하였다.



[그림 4] AI 추천 시스템 구조도

3) 설계(Design): AI 추천 시스템 홈페이지 구축을 위한 스토리보드

웹 페이지 구현을 위한 UI/UX 시안은 스토리보드를 통해 웹 개발자와 소통하였다. [그림 5]는 페이지별로 제시한 스토리보드 일부이다. 본 연구의 연구자와 웹 개발자는 파워포인트로 작성된 스토리보드를 통해 화면배치, 페이지 전환, 클릭 시 등장 도표, 마우스 오버 시 등장 안내 문구 등의 상세한 내용을 의논하고 개발하였다.



(그림 5) AI 추천 시스템 홈페이지 설계 스토리보드 예시

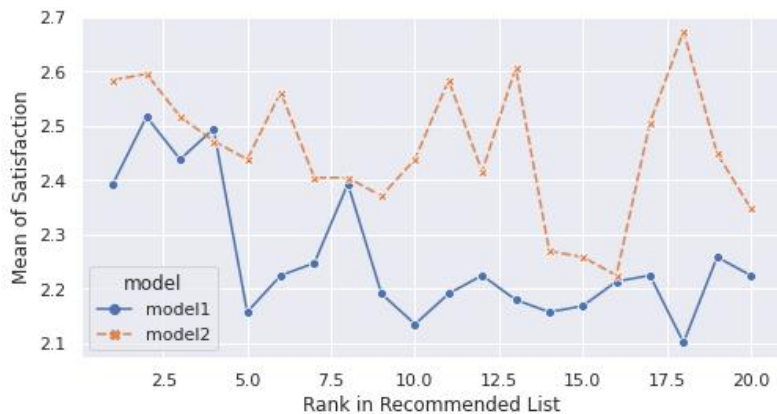
4) 파일럿 테스트(Pilot test)

본 연구에서는 설계와 동시에 머신러닝을 이용한 모델이 개발되었으며 파일럿 테스트는 모델이 추천해주는 결과에 대해서 진행하였다. <표 1>을 바탕으로 한 총 89명의 교내 재학생이 설문조사에 참여하였으며 파일럿 테스트 결과는 다음과 같다.

먼저 파일럿 테스트에 참여한 학생들의 단과대학 분포는 문과대학 23.6%(N=21), 정경대학 19.1%(N=17), 사범대학 15.7%(N=14), 공과대학 11.2%(N=10), 보건과학대학 10.1%(N=9), 생명과학대학 7.8%(N=7) 등으로 구성되었다. 학년 분포는 3학년이 44.9%(N=40) 주를 이루었고, 4학년 33.7%(N=30), 2학년 20.2%(N=18)가 뒤를 이었다. 1학년이 1.12%(N=1)로 가장 적은 응답 학년을 차지했다. 제2전공에 분포는 이중전공, 심화전공이 각각 32.58%(N=29)로 가장 많았으며, 그 뒤로 융합전공 21.34%(N=19), 제2전공없음 10.1%(N=9), 학생설계전공 3.3%(N=3)를 차지하였다.

(1) 추천 강의에 대한 만족도

[그림 6]은 파일럿 테스트 응답자들이 추천된 강의마다 기입한 만족도를 나타낸 것이다. model 1은 학우 기반 추천, model 2는 과목 기반 추천 모델로 학우 기반 추천은 상위에 있는 과목일수록 평균 만족도가 높은 것을 알 수 있고 4위권에서 만족도가 급격히 감소하다가 8위권에서 다소 증가하는 양상을 보인다. 반면 과목기반추천의 경우 학우 기반 추천과는 다르게 18위 지점에서 만족도가 급격히 증가하는 것으로 나타났다.



(그림 6) 추천 강의 순위에 따른 평균 만족도 분포

(2) 추천 모델별 만족도 비교

<표 5>는 전체적인 추천 모델에 대한 만족도를 차이를 t-test 분석을 통해 나타낸 결과이다. 파일럿 테스트에 응한 학생들은 추천 모델에 대한 전반적인 만족도에서 차이를 나타내었으며 학우 기반 추천 모델보다 과목 기반 추천 모델의 만족도가 높은 것을 확인하였다.

<표 5> 파일럿 테스트 추천 모델별 사용자 만족도 비교 ($N = 89$)

모델	만족도		<i>t</i>
	<i>M</i>	<i>SD</i>	
학우 기반 추천	2.19	0.65	-7.847***
과목 기반 추천	2.85	0.64	

*** $p < .001$

<표 6>은 응답한 만족도에 대한 근거에 대한 개방형 문항 응답을 요약하여 제시한 것이다. 학생들은 학우 기반 추천에 대하여 대체로 같은 전공 학생들 사이에서 인기 있는 강의가 추천되었다고 언급하였으며 같은 학과 학생들이 어떤 강의를 수강했는지 궁금한 사용자들에게 도움이 되었다고 하였다. 그러나 필수적으로 수강하여야 하는 강의나 항상 좋은 평을 가진 체육 강의의 경우에는 추천리스트에서 항상 상위권에 위치하기 때문에 추천의 필요성을 느끼지 못하기도 하였다. 또한 학과 학생들과 관심사가 다를 경우에는 추천 결과가 도움되지 않는다고도 응답하였다.

<표 6> 파일럿 테스트 만족 근거 개방형 문항 요약

모델	요약
학우 기반 추천	같은 과 학우지만 친한 친구 외에는 무슨 수업을 듣는지 직접 물어보지 않으면 모르는데 인공지능으로 같은 과 학우들이 들어왔던 수업들을 기반으로 추천을 받으면 정말 도움이 될 것 같습니다.
	실제 지망하는 진로 분야와 연관된 교양 과목들이 많이 제시되었으며, 한편으로는 진로 외 개인적인 관심분야에 해당하는 유형의 교양과목들도 대거 추천되었습니다.
	관심 있는 강의여도 낮은 학점을 받을까봐 수강하지 못한 강의들이 추천되었는데 같은 과 학생들이 많이 수강했었다는 것을 아는 것만으로도 도움이 되었습니다.
	대체로 인기 있고 잘 알려진 강의들 위주로 추천된 것 같습니다.
	나의 관심사가 과 학우들의 관심사와 다를 때는 크게 도움 되지 않는 것 같습니다.
	학생들의 선호 여부와는 관계없는 필수강의가 추천되는 경우에는 신뢰도가 떨어진다고 생각합니다.
과목 기반 추천	졸업 요건인 과목과 추천 하지 않아도 수강할 체육 강의의 경우에는 추천하지 않아도 될 것 같습니다.
	이전에 경험해보지 못한 다양한 분야의 흥미로운 교과목들을 추천해준다는 점에서 마음에 들었습니다.
	비슷한 강의를 수강한 학생들이 선택한 과목들이어서 그런지 수업이 흥미롭게 느껴지고, 미처 몰랐던 교양 과목들의 존재도 새롭게 알게 되었습니다.
	수강하고 싶었지만 수강 신청에 실패했던 강의들이 다수 포함되어 있었습니다.
	과거에 수강했지만 만족하지 못했던 강의와 유사한 강의도 포함되어 있어서 이 부분이 개선되면 좋겠습니다.
	내가 어떤 강의를 수강했다고 해서 계속 그것과 유사한 강의만 수강하고 싶지는 않고 더 다양한 강의를 접해보고 싶습니다.
	필수로 수강해야 하는 강의의 경우에는 추천해주어야 할 필요성을 못 느꼈습니다.

과목 기반 추천의 경우에는 수강 이력이 유사한 학생들이 모인 강의들을 추천해주었기 때문에 대체로 조금 더 개인에게 맞춰진 추천이 이루어졌다고 응답하였다. 관심 있는 강의였지만 수강신청에 실패한 강의들이 등장했다고 언급한 것으로 보아 실제 관심사를 잘 드러내고 있음을 파악할 수 있었다. 그러나 수강 신청에 실패하여 대체 강의를 수강했을 때 모델이 이 역시도 반영하여 추천해주었기 때문에 필터링이 필요하다고 응답하기도 하였다. 또한, 학우 기반 추천과 마찬가지로 필수적으로 수강해야 하는 강의의 경우에는 추천 리스트에서 제외하는 것이 바람직하다고 응답하였다.

5) 최종 산출 프로토 타입

(1) AI 추천 시스템 전달 정보 선정

인터뷰와 파일럿 테스트를 바탕으로 학생들의 요구를 확인하고 유관부서와 공개 가능 범위를 논의한 내용을 바탕으로 AI 기반 교양 강의 추천 시스템은 <표 7>과 같은 내용으로 구성하였다. 학생들은 학우 기반 추천 모델에서 추천된 결과와 과목 기반 추천 알고리즘에서 추천된 2가지의 추천 결과를 확인할 수 있으며, 강의마다 핵심역량, 전공 구성 비율, 학년별 분포, 교수자, 시간표 등의 정보를 확인할 수 있다. 또한 해당

〈표 7〉 AI 기반 교양 강의 추천시스템 구성 내용

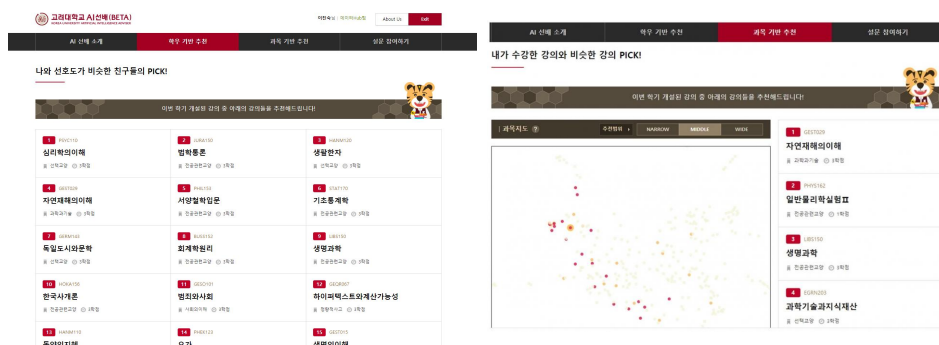
구 분	내용	내용 상세
AI 선배 소개	AI 선배 소개	AI 선배 소개 페이지, 참여 연구진 소개
학우 기반 추천	추천 리스트	사용자 기반 협업 필터링을 통해 도출한 교양 강의 추천
과목 기반 추천	추천 리스트	과목 기반 추천 알고리즘으로 도출한 교양 강의 추천
	강의 지도	유사한 강의끼리 군집화된 시각화 지도
	핵심역량	각 강의에서 습득할 수 있는 핵심역량
강의 상세 정보	제1전공 구성비율	최근 5년간 해당 강의를 수강한 제1전공 구성비율
	제2전공 구성비율	최근 5년간 해당 강의를 수강한 제2전공 구성비율
	학년별 분포	최근 5년간 해당 강의를 수강한 학년별 구성비율
	강의시간표	다음 학기 기준 개설 시간표
	교수님	다음 학기 기준 해당 강의를 담당하실 교수님
	유사 강의	해당 강의와 내용 측면에서 유사한 강의
설문 조사	만족도 조사	만족도 설문조사 링크

대학의 AI 기반 맞춤형 강의 추천 시스템 개발 및 실제 적용 사례 연구: K 대학을 중심으로

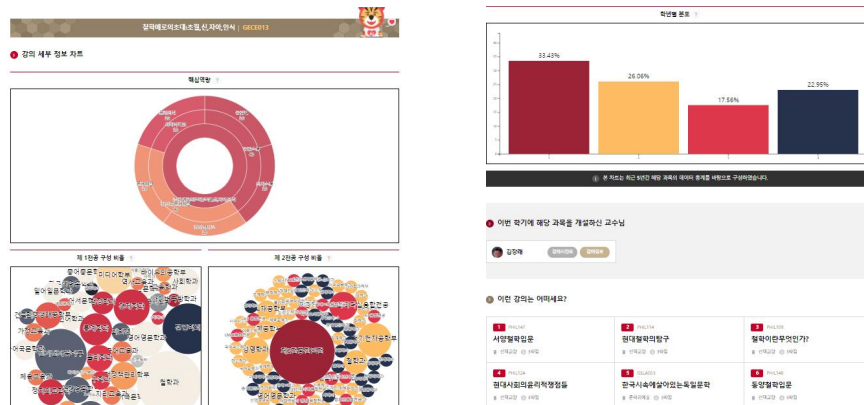
강의와 내용으로 유사한 강의도 확인할 수 있다.

(2) AI 추천 시스템 인터페이스

[그림 7]은 개발이 완료된 추천 시스템의 인터페이스 예시이다. 학생들은 각 모델마다 21개씩의 강의를 추천받게 되며 [그림 8]은 클릭 시 상세정보 페이지로 전환되는 화면의 예시를 나타내었다.



(그림 7) 학우 기반 추천 페이지(왼쪽)와 과목 기반 추천 페이지(오른쪽)



(그림 8) 상세 정보 페이지 예시

2. 서비스 만족도 설문조사 결과

본 연구에서 개발한 AI 기반 교양 강의 추천 서비스는 2020년 7월부터 9월까지 시범 운영하였다. 시범 서비스 동안 만족도 설문조사를 진행했으며 시스템 인터페이스

상단 메뉴에 구글 설문지 링크를 첨부하여 수집하였다. <표 2>에서 제시한대로 일반적인 교양 강의 선택시 고려하는 점, 교양 강의 선택시 필요한 정보와 같이 정보에 대한 요구를 확인하고 모델별 추천 리스트에 대한 만족도를 비교하였다. 또한 서술형 문항을 제시하여 해당 시스템에 대한 의견을 자유롭게 개진하도록 하였다. 총 782건의 응답 중 불성실한 응답과 중복 응답은 제거하고 타 캠퍼스 소속 응답을 제외한 767건의 응답만을 이용하였다. 분석 방법으로는 빈도 분석, 대응표본 t-test를 이용하였다.

1) 응답자 정보

설문 응답자의 기본정보는 다음과 같다. 단과대학 분포는 문과대학 17.8%(N=137), 공과대학 14.3%(N=110), 정경대학 12.6%(N=97), 경영대학 10.5%(N=81), 보건과학대학 9.5%(N=73) 등으로 분포하고 있었으며, 학적 상태는 재학 59.7%(N=458) 상태가 가장 많았고, 휴학 19.9%(N=153), 졸업 13.6%(N=105) 등으로 구성되었다. 응답자의 학년은 졸업자, 제적 상태를 제외하고 4학년이 33.2%(N=255)로 가장 많았고, 3학년 26%(N=200), 2학년 21.9%(N=168), 1학년 3.2%(N=25), 기타 0.2%(N=2)로 분포하였다(<표 8>).

2) 교양 강의 선택

교양 강의 선택에 관련된 문항의 빈도분석 결과는 다음과 같다(<표 9>). 학생들은 교양 강의를 선택할 때 흥미 및 관심사를 중요하게 고려한다는 응답이 34.3%(N=655)로 가장 높았으며, 그 밖에 학습 난이도 및 학습량 22.4%(N=435), 수업 방식 18.9%(N=367), 학점 분포 13.9%(N=270) 등을 중요하게 고려하는 것으로 나타났다. 희망 진로 관련도가 8.5%(N=166)로 가장 낮은 값을 나타낸 것을 통해 학생들은 교양 강의를 진로에 도움되는 강의보다는 흥미 및 관심사 위주로 선택하고 있다고 볼 수 있다.

한편 교양 강의를 선택할 때 필요한 정보에 대한 응답은 <표 10>과 같다. 강의를 나타내는 키워드가 23%(N=377)으로 가장 많은 응답을 차지했으며, 그 다음으로 강의를 통해 얻을 수 있는 핵심역량 21.5%(N=352), 제 1전공 분포 14.6%(N=240) 순으로 나타났다. 제2전공 분포에 대한 정보는 7.1%(N=117)으로 가장 낮은 응답을 차지하였다. 학생들은 교양 강의를 수강할 때 강의를 수강한 학생들의 분포보다는 강의의 키워드나 핵심역량과 같이 내용에 대한 정보에 대한 요구가 가장 높은 것으로 볼 수 있다.

〈표 8〉 AI기반 추천 시스템 서비스 설문조사 응답자 기본 정보

구 분	N	%
문과대학	137	17.8
공과대학	110	14.3
정경대학	97	12.6
경영대학	81	10.5
보건과학대학	73	9.5
생명과학대학	72	9.3
사범대학	63	8.2
이과대학	38	4.9
정보대학	21	2.7
심리학부	20	2.6
미디어학부	17	2.21
국제학부	14	1.8
간호대학	9	1.1
디자인조형학부	8	1.0
기타	7	0.9
합계	676	100
재학	458	59.7
휴학	153	19.9
졸업	105	13.6
수료	39	5.0
제적	9	1.1
조기졸업	3	0.3
합계	676	100
4학년	255	33.2
3학년	200	26.0
2학년	168	21.9
1학년	25	3.2
기타	2	0.2
합계	650	100

〈표 9〉 교양 강의 선택시 중요하게 고려하는 요소(중복응답)

항 목	N	%
흥미 및 관심사	665	34.3
학습 난이도 및 학습량	435	22.4
수업 방식	367	18.9
학점 분포	270	13.9
함양능력	228	11.7
희망 진로 관련도	166	8.5
합계	2,131	100

〈표 10〉 교양 강의 선택시 필요한 정보(중복응답)

교양 강의 선택시 필요한 정보	N	%
강의를 나타내는 키워드	377	23.
핵심역량	352	21.5
제1전공 분포	240	14.6
본전공과의 유사도	192	11.7
관심있는 강의와 유사 과목	178	10.8
관심있는 강의와 유사하지 않은 다른 과목	146	8.9
제2전공 분포	117	7.1
합계	1,602	100

3) 추천 모델별 만족도

교양 강의 추천 서비스를 이용해 본 학생들이 모델에 따라 만족도의 차이가 있는지 분석하기 위하여 대응 표본 t-test를 통하여 수행하였다. <표 11>은 해당 결과를 나타

〈표 11〉 실제 서비스 이용자의 추천 모델별 만족도 (N = 767)

모델	만족도		t
	M	SD	
학우 기반 추천	3.41	1.03	-3.813***
과목 기반 추천	3.57	0.97	

*** $p < .001$

낸 것으로 두 모델의 결과에 대한 평균 만족도는 3.41과 3.57으로 대체적으로 만족하지만 학우 기반 추천 모델보다 과목 기반 추천 모델에 대한 만족도가 유의미하게 높은 것으로 나타났다.

4) 추가 희망 추천 서비스 및 추천 방향

설문조사에 응한 학생들이 원하는 추가적인 희망 추천 서비스는 장학금 추천이 20.8%(N=457)로 가장 많았으며, 진로추천 20.5%(N=452), 비교과 추천 20.2%(N=445), 다전공 추천 18.5%(N=407), 강의 추천 17.8%(N=393) 순으로 응답하였다(<표 12>).

〈표 12〉 추가 희망 추천 서비스(중복응답)

항 목	N	%
장학금 추천	457	20.8
진로 추천	452	20.5
비교과 추천	445	20.2
다전공 추천	407	18.5
강의 추천	393	17.8
합계	2,154	100

또한 희망 강의 추천 방향성에 대한 응답으로는 학문적인 관심과 흥미를 바탕으로 한 추천 서비스에 대한 응답이 26.6%(N=586)로 가장 많았으며, 그 뒤로 희망 진로에 도움이 되는 추천 17.1%(N=377), 선호하는 교수님 및 수업 방식에 따른 추천 16.7%(N=369), 수강소감평가에서 높은 점수를 준 강의와 유사한 추천 13.1%(N=290)

〈표 13〉 희망 교양 강의 추천 방향(중복응답)

항 목	N	%
학문적 관심 및 흥미에 따른 추천	586	26.6
희망진로에 도움이 되는 추천	377	17.1
선호하는 교수님 및 수업 방식에 따른 추천	369	16.7
수강소감평가에서 높은 점수를 준 수업과 유사한 추천	290	13.1
전공 커리큘럼에 도움이 되는 추천	280	12.7
창의융합형 역량 증대에 도움이 되는 추천	158	7.1
합계	2,060	100

등으로 응답하였다(<표 13>). 이는 교양 강의를 선택할 때 흥미와 관심사를 가장 많이 고려한다는 응답과 맥락을 같이한다.

5) 기타 의견

본 연구에서 개발된 추천 서비스에 대한 의견의 서술형 응답에 대한 요약을 나타낸 것이다. 서술형 응답에서 크게 ‘모델별 추천 결과’, ‘긍정적 의견’, ‘개선점’과 관련된 3가지 주요 의견이 도출되었다.

첫째, 설문조사에 응답한 학생들은 전반적으로 강의 추천 서비스에 대해 긍정적인 의견을 보이고 있었다(<표 14>). 생각보다 관심이 있거나 기대했던 강의를 추천되어 신기하고 새로운 강의도 알게 되어 실제 다음 학기 수강계획에 반영할 예정이라고 응답하였다. 또한, 강의를 탐색하는데 소요되는 시간과 노력을 줄일 수 있어 효율적이며, 직접 알아내기 힘든 정보를 광범위한 데이터를 바탕으로 얻을 수 있다는 점에 유용하다고 평가하였다. 더불어 새로운 영역을 탐색할 수 있는 교양 강의의 중요한 역할을 재고할 수 있는 서비스라고 긍정적으로 평가하였는데 단순히 높은 성적을 취득하기 위한 강의 수강이 아니라 해당 서비스를 통해 새로운 학문적 견문을 넓힐 기회를 얻기를 기대하고 있었다.

둘째, 학우 기반 추천의 경우 대체로 과 학우들이 많이 수강한 강의를 추천되었다고 응답하였으며, 같은 학과 학생들 대부분의 취향과 유사한 학생들에게 유용한 결과일 것이라 응답하였다. 더불어 실제로 관심 있게 찾아본 강의들과 친구에게서 들어본 적이 있는 강의들이 등장했다고 하였다. 그러나 비슷한 학우라도 관심사는 충분히 달라질 수 있으므로 관심사가 다른 학우에게는 유용하지 않을 수 있다고도 하였다. 흥미로운 점은 모델의 데이터에는 성적데이터가 포함되지 않았음에도 성적을 쉽게 취득할 수 있는 강의들이 추천되었다는 의견이 존재하는 것을 확인하였다. 한편, 과목 기반 추천의 경우에는 수강했던 강의의 분야에 꾸준한 관심이 있어 비슷한 강의를 추천받고 싶을 때 유용한 결과라고 응답하였다. 더불어 입력 데이터값이 적어도 추천 결과가 우수하다고 평가한 학생도 존재하였다. 그러나 관심사가 바뀌거나 수강 이력과 관련 없는 아주 새로운 강의를 추천받기 원하는 경우 해당 모델의 결과가 유용하지 않을 수 있음을 언급하였다(<표 14>).

셋째, 서비스 개선점에 대한 의견은 추천 방향, 추가 기능, 추천 근거, UI/UX, 접근성 측면으로 구분되었다(<표 15>). 추천 방향 측면의 개선점은 다음과 같다. 개인의 학업적 호기심, 교수자, 학업 난이도가 고려된 서비스를 희망하며 설계팀이 우려했던 부분과 같이 단순히 성적을 잘 받기 위한 강의를 추천되지 않기를 바라는 응답을 확

〈표 14〉 AI 기반 추천 서비스 긍정의견 및 모델 결과 개방형 문항 요약

구분	내용
긍정 의견	생각보다 관심있거나 기대했던 강의가 추천되어 매우 신기하였고 새로운 강의도 알게 되어 실제 다음 학기 수강 계획에 이용할 예정입니다.
	새로운 영역을 탐색할 수 있는 역할을 가진 교양 강의의 중요성을 극대화하는 서비스라고 여겨집니다.
	흥미에 맞는 학습계획을 세우는데 도움이 될 것 같습니다.
	교양 강의 추천이라는 아이디어가 참신하고 직접 알아내기 힘든 정보를 광범위한 데이터를 이용해 얻을 수 있다는 점에 유용합니다.
학우 기반 추천	교양 강의 추천 서비스는 단지 높은 성적을 받기 위한 강의 수강이 아닌 새로운 시각에서 세상을 바라볼 수 있는 기회를 제공할 서비스라고 생각합니다.
	대부분의 같은 과 사람들이 많이 들었던 과목을 추천해주는데 이와 유사한 취향을 가지고 있는 사람이면 만족할 결과로 생각합니다.
	대체로 성적을 받기 쉬운 강의가 추천되었습니다.
	비슷한 학우라도 관심사는 충분히 달라질 수 있기 때문에 이러한 부분 반영되었으면 좋겠습니다.
모델 결과	실제로 관심있게 찾아본 강의들과 친구에게서 들어본 강의들이 등장했습니다.
	수강했던 과목 분야에 꾸준한 관심을 가져 비슷한 강의를 수강하고자 할 때 유용한 결과라고 생각합니다.
	신입생이라 1학기만의 수강이력이 존재함에도 실제로 2학기에 고려하던 강의가 추천되었고 그 외의 추천받은 강의의 수강평을 찾아보니 원하던 형태의 수업이라 실제 수강할 예정입니다.
	나의 관심사와 더욱 맞춰진 강의 추천이라는 인상을 받아 유익했습니다.
과목 기반 추천	내가 수강했던 강의와 유사한 강의를 추천해주기 때문에 새로운 분야를 탐색하기에는 적합하지 않다고 생각합니다.

인할 수 있었다. 또한 당장 이번 학기에 수강할 수 있는 강의만 추천하는 것이 아닌 이후에도 수강할 수 있는 강의를 포괄적으로 추천해주는 커리큘럼 추천의 요구도 확인하였다. 한편 학우 기반 추천 모델과 과목 기반 추천 모델 모두 사용자와 아예 관련 없는 강의는 추천해주지 않는다는 한계점을 지적하며 전혀 생각하지 못했던 강의를 추천받고 싶다는 응답을 확인하였다.

추가로 희망하는 기능은 추천 결과에 반영하고 싶은 강의와 반영하고 싶지 않은 강의를 선택하는 기능과 발표나 시험 여부와 같은 활동 유형을 직접 설정하고 이에 따라 알맞게 추천받는 필터링 기능이 주요 희망 기능으로 도출되었다. 한편 자신의 학습 성향을 진단하는 설문조사가 선행된 뒤 추천을 받는 형식도 다수 언급되었으며 교양 강의는 강의명만으로는 내용을 유추하기 어려운 경우가 많아 강의를 나타내는 키워드를 제시하는 방안도 확인하였다.

추천 근거에 대한 응답은 대체로 모델의 동작 원리에 대해 궁금점을 갖는 학생들이 많았는데 실제 어떤 알고리즘을 사용하여 어떤 데이터를 바탕으로 추천을 받았는지 알고자 하는 요구를 확인하였다.

〈표 15〉 AI 기반 추천 서비스 개선점 개방형 문항 요약

구분	내용
추천 방향	학업적 호기심을 충족할 수 있으면서 학업 난이도가 반영되면 좋겠습니다.
	성적을 잘 받을 수 있는 강의 위주로 추천하게 된다면 수강신청시 경쟁 과열을 야기할 수 있으므로 지양하는 것이 좋을 것 같습니다.
	당장 수강할 수 있는 추천도 필요하지만, 개인의 진로 및 관심사를 기반한 커리큘럼 추천도 필요하다 생각합니다.
	교양 강의는 새로운 영역을 탐색할 수 있는 기회이기 때문에 전혀 생각지도 못했던 강의지만 흥미로운 강의의 추천이 필요합니다.
	같은 강의라도 교수자의 수업방식과 평가방식에 따라 선호도가 달라지기 때문에 선호하는 교수자를 고려한 추천이 필요합니다.
개 선 점	추천 결과에 반영될 강의와 반영시키고 싶지 않은 강의를 선택하여 결과를 산출하는 기능이 추가되면 좋겠습니다.
	발표나 과제, 중간고사 여부 등 강의 방식에 따라 원하는 강의만 추천받는 필터의 기능이 반영되면 좋겠습니다.
	자신의 학습성향 및 선호도를 진단할 수 있는 간단한 설문조사를 진행하고 이를 반영하여 추천을 받을 수 있으면 좋겠습니다.
	교양 강의는 강의명으로 어떤 내용의 강의인지 유추하기 힘들기 때문에 대표 키워드 제시해주면 좋겠습니다.
	근거 추천이 어떤 근거로 이루어졌는지에 대한 상세 설명이 추가되면 좋겠습니다.
UI/UX	직관성이 다소 떨어지는 편이고 상세정보 차트가 한눈에 들어오지 않습니다.
접근성	서비스의 존재를 모르는 학생들이 많아 적극적인 홍보를 해야 할 것 같습니다.

UI/UX와 접근성 측면의 개선점은 인터페이스의 직관성이 다소 떨어지며 상세정보 차트가 난해하여 해석하기 어렵다는 의견이 존재하였다. 또한 아직 해당 서비스의 존재를 모르는 학생들이 많으므로 적극적인 홍보가 필요하다는 의견을 제시하였다.

종합하면 학생들은 교양 강의를 선택할 때 자신의 흥미와 관심사를 가장 중요하게 고려하고 있었으며, 이를 고려한 추천 서비스를 원하고 있음을 파악할 수 있었다. 또한 강의를 요약하여 나타낼 수 있는 키워드와 같이 강의 내용 자체에 대한 정보가 필요한 것으로 나타났다. 더불어 추가적인 추천 서비스에 대하여 장학금 추천 서비스를 가장 원하고 있는 것을 확인하였는데 해당 설문 문항의 중복 응답 건수가 가장 많은 건수를 차지하고 각 항목에 대한 응답의 분포도 비슷한 것으로 미루어보아 제시한 모든 항목의 추천을 원하고 있음을 알 수 있다.

더불어 해당 서비스에 대해 전반적으로 긍정적인 의견을 보이고 있으며, 모델별로 유용하게 느낄 대상이 다름을 확인하였다. 또한 추천에 대한 방향성과 필터링 기능과 같은 추가로 희망하는 기능에 대해 상세히 기술하였고 추천 근거 제공에 대한 요구도 확인하였다. 마지막으로 인터페이스상의 개선점과 홍보 부족 등의 개선점도 도출할 수 있었다.

3. 희망 강의 등록 및 수강 신청 현황 검증 결과

1) 희망 과목 등록 여부

교양 강의 추천 서비스 만족도 설문조사에 응답한 학생들이 2020학년도 2학기 수강신청기간에 희망 과목 목록에 추천 받은 강의를 등록했는지 알아보기 위하여 희망 과목 등록 내역과 모델별 추천 리스트 데이터를 결합하여 Recall@21과 MRR@21을 측정하였다. 설문에 응답한 767명의 학생 중 2020학년도 2학기 수강신청을 위해 희망 교양 강의를 등록한 학생은 445명으로 평균적으로 한 학생당 2.73개의 교양 강의를 등록하였다. 이 때 필수 교양 강의는 추천 리스트에서 제외하는 규칙을 적용하였기 때문에 필수 교양 강의를 희망 강의로 등록한 경우에는 분석 결과에 포함시키지 않았다.

<표 16>은 측정 지표 결과를 나타낸 표이다. 학우 기반 추천에서 Recall@21값은 약 37%로 한 학생이 희망 강의로 등록한 교양 강의 중 37%의 강의를 추천 리스트에 나타난 것으로 확인되었다. 반면 과목 기반 추천에서는 18%의 희망 강의만 추천 리스트에 포함된 것으로 나타났다.

한편, 학우 기반 추천의 MRR@21 측정치는 0.25로 희망 과목으로 등록한 강의는 평균적으로 4위에서 최초로 등장하는 것으로 해석할 수 있다. 반면 과목 기반 추천의 경

우에는 9위인 것으로 나타났다. 다시 말해, 학우 기반 추천을 통해 추천 받은 강의에서는 4위권에서 희망 과목 등록이 이루어졌고, 과목 기반 추천에서는 9위권에서 희망 과목 등록이 이루어졌음을 뜻한다.

2) 추천 강의 수강 여부

추천 서비스 만족도 설문조사에 응답한 학생들이 2020학년도 2학기에 실제 추천받은 강의를 수강했는지 알아보기 위하여 수강 이력 데이터와 추천받은 강의 데이터를 결합하여 Recall@21과 MRR@21을 측정하였다. 설문에 응답한 767명의 학생 중 2020학년도 2학기에 교양 강의를 신청한 학생은 총 86명으로 평균적으로 2.53개의 교양 강의를 신청하였다. 역시 교양 강의는 필수 교양 강의는 추천 리스트에서 제외하였기 때문에 필수 교양 강의를 수강한 경우에는 분석 결과에 포함하지 않았다.

<표 16>은 측정 지표 결과를 나타낸 표이다. 학우 기반 추천에서 Recall@21값은 약 43%로 한 학생당 평균적으로 상위 21개의 추천된 강의에서 약 43%의 강의를 수강한 것으로 나타났다. 반면 과목 기반 추천에서는 추천 리스트의 약 14%의 강의만 수강한 것으로 나타났다.

한편, 학우 기반 추천의 MRR@21 측정치는 0.25로 상위 21개의 추천 리스트에서 학생들이 첫째로 수강한 강의의 순위는 평균적으로 4위에서 등장하는 것으로 나타났다. 반면 과목 기반 추천의 MRR@21값은 0.06으로 16위인 것으로 나타났다. 즉, 학우 기반 추천은 대체로 리스트의 4위권에서 강의 수강이 이루어지는 것을 뜻하며 과목 기반 추천에서는 평균적으로 16위권에서 강의 수강이 이루어지는 것을 뜻한다. 해당 결과는 파일럿 테스트의 강의별 만족도 조사 결과와 같은 맥락으로 과목 기반 추천 모델에서 강의 선택은 순위에 영향을 받지 않은 것으로 해석할 수 있다.

〈표 16〉 모델별 사후 추적 조사 결과

구분	모델	지 표	
		Recall@21	MRR@21
희망 과목 등록 (N=445)	학우 기반 추천	37.1%	0.25
	과목 기반 추천	18.5%	0.11
수강 신청 (N=86)	학우 기반 추천	43.3%	0.25
	과목 기반 추천	14.3%	0.06

V. 결 론

본 연구에서는 적응형 학습의 일종인 인공지능 기반 강의 추천 서비스 개발을 위하여 래피드 프로토타입 교수 모형에 반영하고 실제 교내 포털 사이트에 적용하여 이용자의 만족도 및 사후 행동에 관한 분석을 진행하고자 하였다. 본 연구의 논의는 다음과 같다.

첫째, 래피드 프로토타입 모형은 개인화된 AI 기반 강의 추천 시스템 개발에 적합한 것으로 확인하였다. 본 연구에서 최종적으로 이용자에게 전달된 결과물의 형식은 웹 브라우저이기 때문에 개발 과정은 기존의 웹 개발 수업 프로그램 연구(임철일 외, 2005)에 이용되는 모형을 적용하기에 충분함을 확인하였다. 설계부터 개발까지 중첩으로 진행되어 효율성이 높았고, 더불어 개발 과정에 사용자가 참여하여 사용자의 의견을 빠르게 반영할 수 있어 한정된 일정에 개발 과정을 완료할 수 있었다. 이는 알고리즘 개발에 사용자의 요구를 반영하기 위해 관련 데이터를 탐색해야 했으므로 선형적인 기존의 모형과 달리 병렬 또는 중첩으로 진행할 수 있었다는 측면에서 더욱 적합하였다고 할 수 있다.

둘째, AI 기반 추천 서비스 만족도 설문조사의 결과를 통해 대체로 학생들은 해당 서비스에 대해 긍정적인 반응을 확인하였으며, 과목 기반 알고리즘이 학우 기반 알고리즘보다 유의미하게 높은 만족도를 나타냈다. 이전에는 알지 못했던 새로운 강의를 알게 되었기 때문으로 개방형 문항을 통해 파악하였다. 또한 학우 기반 알고리즘의 만족도를 높게 평가한 학생의 경우 주변에서 많이 수강하고 있는 강의를 알게 되었기 때문으로 응답하였다.

셋째, 2020년 2학기에 희망 강의로 등록된 내역과 실제 수강 내역에서 추천된 강의를 분석했을 때 학우 기반 추천 알고리즘의 Recall이 각각 약 37%와 43%로 과목 기반 알고리즘의 결과인 18%와 14%에 비해 높은 것으로 나타났다. 다시 말해, 학우 기반 알고리즘의 결과가 향후 학생들이 수강할 강의들을 더 잘 맞추었다고 볼 수 있다.

본 연구의 결론과 제언은 다음과 같다.

첫째, 본 연구에서 제시한 학우 기반 추천과 과목 기반 추천 기능은 사용자의 요구에 따라 다르게 이용될 수 있음을 확인하였다. 먼저 학우 기반 추천 모델은 나와 같은 전공 학생 내에서 유사한 선호를 가진 학우들의 수강 이력을 통해 추천해주기 때문에 수강 이력에 대한 정보가 상대적으로 적은 저학년이나 주변 학우들의 흥미나 관심도가 반영된 결과를 얻고자 할 때 유용할 수 있다. 또한, 과목 기반 모델은 자신의 수강 내역만 고려했기 때문에 과거 수강했던 강의에 대해 선호를 가지고 꾸준한 관심을 두

고 있는 학생의 경우 유용하게 이용할 수 있다. 따라서 향후 개선될 프로그램에는 사전의 원하는 추천 방향에 대한 선택지를 주고 그에 맞는 추천 리스트를 제공할 필요가 있다.

둘째, 강의 추천 서비스를 이용한 학습자가 느끼는 만족도와 실제 희망 강의 등록 및 수강 신청 현황과는 차이가 있음을 확인하였다. 이는 사용자가 느끼는 추천 결과의 만족도는 과목 기반 추천 모델이 높았을지라도 실제 수강하게 될 강의들은 학우 기반 추천 모델에서 더 많이 등장하였다는 뜻으로 학우 기반 추천이 현실 반영도가 높다고도 해석할 수 있다. 이는 현재 교내의 강의 선택에 있어 수강 학과 제한, 정원 제한 등 여러 가지 요소가 복합적으로 작용하기 때문으로 사료된다. 다시 말해 기존의 학과 학생들이 추천 리스트에 등장한 강의를 많이 수강할 수밖에 없었던 요소가 존재하는 것이다. 교육 분야에서 인공지능을 활용한 추천 시스템을 개발할 때는 이용자가 느끼는 만족도와 알고리즘이 얼마나 예측을 잘했는지 어느 한 쪽에만 치중할 수 없기 때문에 여러 파일럿 테스트를 거치고 알고리즘의 성능 지표를 모두 고려하여 적절한 결과를 산출하는 것이 중요하다고 할 수 있다.

셋째, 앞서 언급한 알고리즘별 만족도와 관련하여 과목 기반 추천의 경우 알지 못했던 강의를 알게 되어 만족했다는 의견이 다수 존재하고, 학우 기반 추천의 경우에는 이미 알고 있는 강의가 추천되었다는 의견이 존재하였다. 이는 의외성이 높은 결과를 얻었을 때 만족도가 증가했음을 의미한다. 이는 Pardos와 Jiang(2020)의 추천 결과에 대한 우연성(Serendipity) 연구처럼 실제로 수강 가능 여부를 떠나 정보가가 높은 결과에 높은 만족을 느낀다는 결과와 일맥상통한다. 따라서 후속 연구에서는 추천 시스템의 성능 및 만족도를 측정하고자 할 때 설문 문항에 해당 개념을 접목하여 새롭게 구성할 필요가 있다.

넷째, 파일럿 테스트의 추천 순위에 따른 만족도 결과와 실제 서비스 이후 사후 추적 조사의 MRR@21 결과값을 통해 학우 기반 추천 모델이 과목 기반 추천 모델보다 상대적으로 만족도에 추천 순위의 영향을 받는 것을 확인하였다. 이는 사용자의 만족도를 높이기 위해서는 모델마다 추천해주는 강의의 개수를 달리하거나 과목 기반 모델의 후순위의 강의를 상위권으로 올릴 수 있는 방안을 모색해야 한다.

다섯째, 학생들은 교양 강의를 선택할 때 흥미 및 관심사를 가장 많이 고려하는 것으로 나타났으며, 이를 바탕으로 한 추천이 이루어지기를 희망하고 있었다. 이는 상대적으로 전공 강의보다는 개인의 선호가 반영될 수 있는 강의의 유형이기 때문으로 해석할 수 있다. 이에 본 연구에서 개발한 교양 강의 추천 시스템은 단순히 성적 취득을 목적으로 하는 강의가 아닌 학생들의 학문적인 견문을 넓히고 새로운 사고의 기회를

제공할 수 있는 시스템으로 자리 잡아야 할 것이다.

본 연구의 다음과 같은 한계점을 포함한다. 첫째, 현재 재학생의 입학년도는 2013년도 이전에 입학한 학생들도 존재하며 이들의 경우 추천 결과를 받지 못한다. 이는 2013년 이후의 강의 수강 평가 문항과 2013년 이전의 강의 수강 평가 문항이 다르기 때문이다. 적합성이 보장된 양질의 데이터를 확보하는 것은 모든 인공지능 개발자가 겪는 문제로 교내에 적재되어 있는 데이터의 맥락을 파악하여 보다 포괄적인 양질의 데이터 확보가 필요하다. 둘째, 추천 결과에 대한 만족도를 측정하고자 할 때 보다 견고한 측정 도구가 개발되어야 한다. 일반적인 인공지능 추천 알고리즘의 평가는 Recall과 MRR로 측정하는 경우가 많다. 그러나 교육 도메인에 추천 시스템이 적용되었을 때는 다른 접근이 요구된다. 즉, 해당 시스템이 학문적인 견해를 넓혀주는 의미의 교육적 함의를 지닌 알고리즘으로 바라볼 때 학습자의 만족도는 단순히 모델이 다음 학기에 수강할 강의를 얼마나 잘 예측하였는가와 다른 문제이기 때문이다. 또한 실제 수강 행동에 이어졌다고 하더라도 추천 시스템이 얼마나 관여하였는지는 본 연구에서는 나타나지 않았기 때문에 관련 측정 도구 개발과 같은 연구가 필요하다. 셋째, 웹페이지 설계에 과정에서 교육적인 요소를 추가적으로 고려할 필요가 있다. 김미량(2000)의 연구에서 제시하는 바와 같이 인공지능이 적용된 웹사이트는 우리에게 수많은 교육적인 가능성을 제공해줄 환경이다. 따라서 화면 설계 역시 웹개발자의 단순 취향이나 개인적인 경험에서 비롯되어 개발되는 것이 아니라 학습자의 몰입을 촉진시키고 주체적인 정보 탐색, 발견, 조직하는 총체적인 학습 경험을 고려해야 한다.

그러나 본 연구에서 제시한 대학 교육에서의 AI 기반 추천 시스템은 단순 강의 추천의 기능을 넘어 학생 활동 전반의 안내자 역할로 자리 잡을 수 있다는 함의를 가진다. 학생들은 제2전공, 장학금, 진로, 비교과 활동 추천서비스와 같이 학생들의 캠퍼스 생활에 필요한 맞춤형 정보를 고르게 원하고 있었다. 이는 권선아 외(2018)의 연구 결과와 맥을 같이 한다. AI 기반 추천 시스템은 정보의 격차를 완화하고 캠퍼스 생활 전반에 대한 불안감을 해소시켜 결과적으로 심리적, 정서적인 돌봄까지 반영될 수 있는 시스템으로 기여할 수 있다.

본 연구에서는 면대면 접촉이 불가능한 현재 상황에서 학생들의 지속 가능한 대학 생활과 정보의 격차를 완화하기 위함을 목적으로 AI 기반 강의 추천 시스템을 개발하였다. 향후 개발되는 교육 분야에 적용되는 인공지능 기반 추천 시스템에는 양질의 데이터를 바탕으로 다양한 주제의 교육적인 추천 기능이 포함되기를 기대하는 바이며, 인공지능이 학습자가 직면하는 정보의 격차와 의사결정 및 학습 과정의 어려움을 해소시킬 수 있는 중요한 기술로 발전하기를 희망한다.

참고문헌

- 권선아, 이재경, 권숙진 (2018). 대학의 인공지능 도입과 인공지능 교수에 대한 학습자 인식. *교육종합연구*, 16(3), 77-101.
- (Translated in English) Kyun, S., Yi, J., & Kwon, S. (2018). Students' perception of universities' introduction of artificial intelligence and of the artificial intelligence professors. *The Journal of Educational Research*, 16(3), 77-101.
- 김두형, 신우석, 한기웅, 이진숙, 문기범, 이수강, 한수연, 권혜정, 한성원 (2020). 협업 필터링을 활용한 대학 교양과목 추천 시스템. *대한산업공학회 추계학술대회 논문집*, 2551-2556.
- (Translated in English) Kim, D., Shin, W., Han, K., Lee, J., Moon, K., Lee, S., Han, S., Kwon, H., & Han, S. (2020). System for recommending university liberal arts courses using collaborative filtering. *Journal of the korean institute of industrial engineers*. 2551-2556.
- 김미량 (2000). 학습자 중심 웹 기반 교수-학습체제의 화면설계 전략. *교육공학연구*, 16(4), 51-76.
- (Translated in English) Kim, M. (2000). Strategies on screen design of learner-centered web-based instructional systems. *Journal of educational technology*, 16(4), 51-76.
- 김충일, 최남규, 허유진, 신지훈, 윤장혁 (2015). 혼합필터링 (Hybrid Filtering) 을 활용한 교과목 추천시스템 개발. *엔트루 저널*, 14(2), 71-82.
- (Translated in English) Kim, C., Choi, N., Heo, Y., Sin, J., & Yoon, J (2015). On the development of a course recommender system: A hybrid filtering approach. *Entrue journal of information technology*, 14(2), 71-82.
- 나일주, 정현미 (2001). 웹기반 가상교육 프로그램 설계를 위한 활동모형 개발. *교육공학연구*, 17(2), 27-52.
- (Translated in English) Rha, I., & Chung, H. (2001). Developing an action model for WBI design. *Journal of educational technology*, 17(2), 27-52.
- 임철일, 김민강, 김윤정 (2005). 웹 기반 수업 개발을 위한 인쇄물 기반의 래피드 프로토타입 개발 방법론에 관한 연구. *교육공학연구*, 21(1), 3-28.
- (Translated in English) Lim, C., Kim, M., & Kim, Y. (2005). A developmental study on the paper-based rapid prototyping methodology for Web-based instruction. *Journal of educational technology*, 21(1), 3-29.
- 손기락, 김소현 (2007). 협동적 필터링을 이용한 K-최근접 이웃 수강 과목 추천 시스템.

정보교육학회논문지, 11(3), 281-288.

(Translated in English) Sohn, K., & Kim, S. (2007). K-nearest neighbor course recommender system using collaborative filtering. *Journal of The Korean Association of Information Education*, 11(3), 281-288.

유재준, 유준영, 조재춘 (2020). kNN 알고리즘 기반의 교양과목 추천 모델 연구. 한국 컴퓨터교육학회 학술발표대회논문집, 24(1), 107-109.

(Translated in English) Yoo, J., Yoo, J., & Cho, J. (2020). A study on liberal arts subject recommended model based on kNN algorithm. *The korean association of computer education*, 24(1), 107-109.

윤장혁 (2016). 협업 필터링을 응용한 대학 교양과목 추천. ie 매거진, 23(1), 37-42.

(Translated in English) Yoon, J. (2016) Recommend college liberal arts courses applying collaborative filtering. *Industrial Engineering Magazine*, 23(1), 37-42

Laberge, R. (2009). *The data warehouse mentor: Practical data warehouse and business intelligence insights*. 장효성 역 (2013). 데이터 웨어하우스 멘토: 실용적 DW/BI 시스템 구축을 위한 통찰. 서울: 비제이퍼블릭

Angus, G., Martinez, R., Stevens, M., & Paepcke, A. (2019). Via: Illuminating academic pathways at scale. In *Proceedings of the Sixth ACM Conference on Learning@ Scale*, 1-10.

Bloom, B. (1984). The 2 sigma problem: The search for methods of group instruction as effective as one-to-one tutoring. *Educational researcher*, 13(6), 4-16.

Bobadilla, J., Ortega, F., Hernando, A., & Gutiérrez, A. (2013). Recommender systems survey. *Knowledge-based systems*, 46, 109-132.

Brusilovsky, P. (2003). Developing adaptive educational hypermedia systems: From design models to authoring tools. In *Authoring tools for advanced technology Learning Environments*. Springer, Dordrecht.

Chaturapruek, S., Dalberg, T., Thompson, M., Giebel, S., Harrison, M., Johari, R., & Kizilcec, R. (2021). Studying undergraduate course consideration at scale. *AERA Open*, 7, 2332858421991148.

Chaturapruek, S., Dee, T., Johari, R., Kizilcec, R. & Stevens, M. (2018). How a data-driven course planning tool affects college students' GPA: Evidence from two field experiments. In *Proceedings of the Fifth Annual ACM Conference on Learning at Scale*, 1-10.

- Dudani, S. (1976). The distance-weighted k-nearest-neighbor rule. *IEEE Transactions on Systems, Man, and Cybernetics*, (4), 325-327.
- Goldberg, D., Nichols, D., Oki, B., & Terry, D. (1992). Using collaborative filtering to weave an information tapestry. *Communications of the ACM*, 35(12), 61-70.
- Gruver, N., Malik, A., Capoor, B., Piech, C., Stevens, M., & Paepcke, A. (2019). Using latent variable models to observe academic pathways. *arXiv preprint arXiv:1905.13383*.
- He, X., Liao, L., Zhang, H., Nie, L., Hu, X., & Chua, T. (2017, April). Neural collaborative filtering. In *Proceedings of the 26th international conference on world wide web*, 173-182.
- Henze, N., & Nejdll, W. (2004). A logical characterization of adaptive educational hypermedia. *New review of hypermedia and multimedia*, 10(1), 77-113.
- Hu, Y., Koren, Y., & Volinsky, C. (2008). Collaborative filtering for implicit feedback datasets. In *2008 Eighth IEEE International Conference on Data Mining*, 263-272
- Jones, T., & Richey, R. (2000). Rapid prototyping methodology in action: A developmental study. *Educational Technology Research and Development*, 48(2), 63-80.
- Lu, J., Wu, D., Mao, M., Wang, W., & Zhang, G. (2015). Recommender system application developments: A survey. *Decision support systems*, 74, 12-32.
- Mikolov, T., Grave, E., Bojanowski, P., Puhersch, C., & Joulin, A. (2017). Advances in pre-training distributed word representations. *arXiv preprint arXiv:1712.09405*.
- Montebello, M. (2018). *AI injected e-learning*. Cham: Springer International Publishing.
- Paramythis, A., & Loidl-Reisinger, S. (2003). Adaptive learning environments and e-learning standards. In *Second european conference on e-learning*, 1(2003), 369-379.
- Pardos, Z., Fan, Z., & Jiang, W. (2019). Connectionist recommendation in the wild: on the utility and scrutability of neural networks for personalized course guidance. *User modeling and user-adapted interaction*, 29(2), 487-525.
- Pardos, Z., & Jiang, W. (2020). Designing for serendipity in a university course recommendation system. In *Proceedings of the tenth international conference on learning analytics & knowledge*, 350-359.
- Pardos, Z., & Nam, A. (2020). A university map of course knowledge. *PLoS one*, 15(9), e0233207.
- Pazzani, M. (1999). A framework for collaborative, content-based and demographic filtering. *Artificial intelligence review*, 13(5), 393-408.

대학의 AI 기반 맞춤형 강의 추천 시스템 개발 및 실제 적용 사례 연구: K 대학을 중심으로

Shao, E., Guo, S., & Pardos, Z. (2021) Degree planning with PLAN-BERT: Multi-semester recommendation using future courses of interest. In *Proceedings of the 35th AAAI Conference on Artificial Intelligence*.

© 논문접수: 2021. 05. 21 / 1차 수정본 접수: 2021. 06. 13 / 게재승인: 2021. 06. 19